Relatório de Entrega

Sumário

Introdução **3**

Metodologia Proposta **3**

Conclusões sobre variáveis disponibilizadas inicialmente **5**

Detalhamento das Etapas e Desafios Encontrados 5

Estratégias Adotadas na Modelagem (Com Dados Limitados) 6

Relatório de Projeto: Predição de Falhas em Injetoras de Borracha (pasta last-dataset) 6

Relatório de Tratamento de Dados com Esquemas de Dados: 6

Insights de Análise Exploratória (explo_data_ijXXX.ipynb) 10

- **Análise Descritiva:** 10
  - **Análise de Variáveis Categóricas:** 11
  - **Principais Descobertas:** 11
  - **Resumo das Quantidades:** 12
  - **Valores Únicos:** 13
  - **Análise de Correlação:** 13
- **Estatísticas Descritivas:** 14
  - **Histogramas:** 14
  - **Gráfico de Dispersão:** 14
  - **Box Plot de Consumo de Massa:** 14
  - **Valores Únicos de Manutenção:** 15
  - **Correlação entre Manutencao e outras variáveis:** 15
  - **Estatísticas descritivas para Descrição da massa (Composto) específica:** 15
  - **Estatísticas descritivas para Descrição da massa (Composto) = F420/95:** 15
- **Gráficos de Dispersão:** 16
- **Observações Gerais:** 16
- **Modelagem e Aprendizado de Máquinas:** 16

Predição de Falhas em Injetoras de Borracha (prediction_01.ipynb) 17
Dados e Pré-processamento: 17
Engenharia de Recursos: 18
Seleção de Modelos: 18
Treinamento e Avaliação dos Modelos: 19
Comparação e Resultados dos Modelos: 19
Importância das Variáveis: 19
Conclusões Iniciais: 19
Recomendações: 20
Considerações Finais: 20
Relatório Detalhado de Análise de Dados de Produção Industrial e Previsão de Manutenção utilizando Hyperparametros (prediction_02.ipynb) 20
Introdução 20
Metodologia 21
Coleta e Preparação dos Dados: 21
Treinamento e Avaliação dos Modelos: 21
Ajuste de Hiperparâmetros: 22
Seleção do Melhor Modelo: 22
Visualização dos Resultados: 22
Resultados Detalhados 22
Desempenho dos Modelos 22
Análise do Modelo Random Forest: 23
Ajuste de Hiperparâmetros: 23
Visualização dos Resultados: 23
Conclusões 23
Próximos Passos e Recomendações 24

Introdução

Este relatório detalha a aplicação de técnicas de Machine Learning para prever a necessidade de manutenção em injetoras de borracha, utilizando dados de produção da Sabó. O objetivo principal é otimizar o tempo de troca do fuso e da camisa da extrusora, reduzindo paradas não planejadas e aumentando a eficiência da manutenção. O projeto envolveu a coleta e análise de dados de produção, como quantidade produzida, quantidade refugada, quantidade retrabalhada e consumo de massa. A metodologia utilizada abrangeu as etapas de Coleta de Dados, Análise Exploratória, Modelagem Preditiva e Validação, com a aplicação de algoritmos como Regressão Linear, Random Forest, Decision Tree e XGBoost. Os resultados indicam que o modelo XGBoost apresentou o melhor desempenho na previsão do tempo restante até a próxima manutenção. Adicionalmente, o relatório descreve os desafios encontrados durante o projeto, como a limitação na quantidade de dados disponíveis, e as soluções adotadas para superá-los, como a solicitação de dados adicionais e o foco em modelos mais simples.

Metodologia Proposta

A metodologia deste projeto foi concebida para ser iterativa e adaptativa, visando a construção de um modelo preditivo robusto para prever a necessidade de manutenção em injetoras de borracha, utilizando dados de produção da Sabó. O projeto abrangeu as seguintes etapas:

- **Coleta e Preparação dos Dados:**
  1. Os dados foram coletados de múltiplos arquivos CSV, cada um contendo informações sobre a produção de uma injetora específica, como quantidade produzida, quantidade de refugo, quantidade retrabalhada, tipo de composto utilizado, entre outros.
  2. Os dados foram pré-processados, combinando os conjuntos de dados de diferentes injetoras em um único Data Frame e codificando as variáveis categóricas, como "Cód. Produto", "Descrição da massa (Composto)" e "Cód. Recurso", utilizando One-Hot Encoding.

- **Engenharia de Recursos:**

3. Variáveis cumulativas foram criadas para "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada", "Fator Un." e "Consumo de massa no item em (Kg/100pcs)".

4. A coluna "Data de Produção" foi convertida para o tipo de dado date time e utilizada para calcular a variável "Manutenção", que representa o número de dias até a próxima manutenção.

- **Seleção de Modelos:**

5. A seleção dos modelos de Machine Learning foi baseada na natureza da variável alvo ("Manutenção"), que é numérica e contínua.

6. Os seguintes modelos foram selecionados para a análise: Regressão Linear, Random Forest, Decision Tree e XGBoost.

- **Treinamento e Avaliação dos Modelos:**

7. A variável "Manutencao" foi definida como a variável alvo (y), e as demais colunas numéricas, exceto "Cód. Un.", foram utilizadas como variáveis preditoras (X).

8. Os dados foram divididos em conjuntos de treinamento (80%) e teste (20%) utilizando a função train_test_split.

9. Cada modelo foi treinado com os dados de treinamento e testado com os dados de teste, utilizando métricas como R^2 e MSE para avaliar a qualidade da previsão.

- **Comparação e Resultados dos Modelos:**

10. Os modelos foram comparados com base em métricas como R^2 e MSE.

11. O XGBoost apresentou o melhor desempenho, com o menor MSE e o maior R^2.

- **Importância das Variáveis:**

12. A análise da importância das variáveis revelou que a variável "Cód. Ordem" é a mais importante para a previsão.

A metodologia proposta inclui um processo iterativo de avaliação, refinamento e validação, garantindo que o modelo final seja robusto, confiável e adequado aos objetivos da Sabó. Adicionalmente, o projeto considerou a qualidade e a viabilidade dos dados como fatores importantes para a modelagem.

Conclusões sobre variáveis disponibilizadas inicialmente

As variáveis inicialmente selecionadas para o experimento – que incluem Intervalo de Medição, Fabricante, Diâmetros (em cinco regiões distintas da camisa e do fuso), Dureza das Peças, Granularidade e Volume do Material Injetado – são reconhecidamente relevantes para a compreensão e a predição do desgaste em injetoras de borracha. Contudo, a base de dados disponibilizada inicialmente apresentou uma limitação significativa em termos de volume de dados.

O principal fator limitante reside na frequência das medições, realizadas apenas uma vez ao ano, por ocasião da troca dos componentes. Essa periodicidade, embora compreensível do ponto de vista operacional, restringe a quantidade de dados disponíveis para cada conjunto de fuso e camisa, inviabilizando a construção de um modelo preditivo robusto e com capacidade de generalização. Modelos de aprendizado de máquina, em especial os mais complexos, necessitam de uma quantidade substancial de dados para serem treinados de forma eficaz e para que possam capturar as nuances e padrões complexos que regem o fenômeno do desgaste.

Para contornar essa limitação, foi formalizada em 03/12/2024 uma solicitação à Sabó para o fornecimento de uma base de dados complementares e mais detalhadas, conforme especificado em e-mail enviado ao Bruno (Sabó). Essa nova base de dados foi crucial para integrar as análises e possibilitar a aplicação das técnicas de modelagem preditiva previstas no escopo do projeto. Com um volume de dados mais expressivo e com uma granularidade temporal mais fina, seria possível treinar modelos com maior acurácia e confiabilidade.

Detalhamento das Etapas e Desafios Encontrados

1. Coleta de Dados: A coleta de dados foi realizada conforme planejado, com a extração de informações do SAP e sua relação com os dados do arquivo Medições_Fuso_Cilindro_RM.195.xlsx. Entretanto, a base de dados inicialmente disponibilizada, com um volume de dados inferior ao esperado (conforme detalhado na seção "Variáveis Disponibilizadas"), mostrou-se insuficiente para a construção de um modelo preditivo robusto. Uma solicitação formal de dados complementares foi enviada à Sabó em 03/12/2024, detalhando as variáveis e o formato necessários para prosseguir com o projeto.

2. Análise Exploratória: Mesmo com as limitações dos dados iniciais, uma análise exploratória preliminar foi conduzida. Essa análise teve como objetivo identificar padrões, outliers e tendências que pudessem fornecer insights sobre o desgaste das peças. A análise confirmou a relevância das variáveis inicialmente selecionadas (Intervalo de medição, Fabricante, Diâmetros, Dureza, Granularidade, etc.), mas também evidenciou a necessidade de um conjunto de dados mais amplo e completo para a obtenção de resultados conclusivos.

3. Modelagem Preditiva: A etapa de Modelagem Preditiva foi a mais impactada pela indisponibilidade dos dados complementares. Diferentes algoritmos de Machine Learning foram considerados para teste, incluindo Regressão Linear, Regressão Polinomial, Árvores de Decisão, Random Forest, XGBoost. A seleção do(s) algoritmo(s) mais adequado(s) seria feita com base em seu desempenho nas métricas de validação (Precisão, Recall, F1-Score e AUC), após o treinamento com a base de dados completa.

Estratégias Adotadas na Modelagem (Com Dados Limitados)

- Testes Preliminares com Algoritmos Diversos: Mesmo com a base de dados limitada, foram realizados testes preliminares com os algoritmos mencionados acima, utilizando técnicas de validação cruzada (como k-fold cross-validation) para minimizar o risco de overfitting. O objetivo era avaliar o potencial de cada algoritmo e identificar aqueles que se mostravam mais promissores para o problema em questão.
- Foco em Modelos Mais Simples: Devido à escassez de dados, a ênfase inicial foi em modelos mais simples, como Regressão Linear e Árvores de Decisão, que são menos propensos a overfitting quando treinados com conjuntos de dados pequenos.

Relatório de Projeto: Predição de Falhas em Injetoras de Borracha (pasta last-dataset)

Relatório de Tratamento de Dados com Esquemas de Dados:

O tratamento de dados visa preparar os dados brutos para análise e modelagem preditiva, garantindo a qualidade, consistência e relevância das informações. O código em Python, utilizando a biblioteca Pandas, foi aplicado para realizar as seguintes etapas de tratamento de dados:

1. Coleta e Organização Inicial dos Dados:

Primeiramente, os dados de equipamentos e datas foram coletados e organizados em listas. Em seguida, as datas foram convertidas para o formato date time e, por fim, formatadas como "YYYY-MM-DD". Um dicionário foi criado para armazenar as informações de equipamentos e datas.

2. Cálculo de Dias até a Manutenção e Criação de Novas Variáveis:

Para cada equipamento, o número de dias até a data final da manutenção foi calculado e armazenado em uma nova coluna chamada "Manutenção". As colunas "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada" e "Fator Un." foram agrupadas por "Manutenção", e as somas cumulativas foram calculadas para cada grupo.

3. Limpeza e Conversão de Dados Numéricos:

A coluna "Consumo de massa no item em (Kg/100pcs)" teve seus dados limpos e convertidos para o tipo numérico. As somas cumulativas também foram calculadas para essa coluna, agrupando por "Manutenção".

4. Agrupamento e Ordenação dos Dados:

Os dados foram agrupados por "Manutenção", e os últimos valores de cada grupo foram armazenados em um novo Data Frame. Em seguida, os dados foram ordenados em ordem decrescente de "Manutenção".

5. Cálculo de Somas Cumulativas Totais:

Novas colunas com as somas cumulativas totais de "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada", "Fator Un." e "Consumo de massa no item em (Kg/100pcs)" foram adicionadas ao DataFrame.

Esquemas de Dados:

- Dados Brutos:
  - Data de Produção: Data de produção (datetime).
  - Cód. Ordem: Código da ordem de produção (int).
  - Cód. Recurso: Código do recurso (object).
  - Cód. Produto: Código do produto (object).
  - Qtd. Produzida: Quantidade produzida (int).
  - Qtd. Refugada: Quantidade refugada (int).
  - Qtd. Retrabalhada: Quantidade retrabalhada (int).
  - Fator Un.: Fator unitário (int).
  - Cód. Un.: Código da unidade (object).
  - Descrição da massa (Composto): Descrição do composto (object).

    - Consumo de massa no item em (Kg/100pcs): Consumo de massa (float).
- Dados Tratados:
    - Manutencao: Dias até a manutenção (int).
    - Cód. Ordem: Código da ordem de produção (int).
    - Cód. Recurso: Código do recurso (object).
    - Cód. Produto: Código do produto (object).
    - Qtd. Produzida: Quantidade produzida (int).
    - Qtd. Refugada: Quantidade refugada (int).
    - Qtd. Retrabalhada: Quantidade retrabalhada (int).
    - Fator Un.: Fator unitário (int).
    - Cód. Un.: Código da unidade (object).
    - Descrição da massa (Composto): Descrição do composto (object).
    - Consumo de massa no item em (Kg/100pcs): Consumo de massa (float).
    - Qtd. Produzida Acumulada Total: Soma cumulativa total da quantidade produzida (int).
    - Qtd. Refugada Acumulada Total: Soma cumulativa total da quantidade refugada (int).
    - Qtd. Retrabalhada Acumulada Total: Soma cumulativa total da quantidade retrabalhada (int).
    - Fator Un. Acumulado Total: Soma cumulativa total do fator unitário (int).
    - Consumo de massa no item em (Kg/100pcs) Acumulado Total: Soma cumulativa total do consumo de massa (float).

O código gen_data_ij.ipynb desenvolvido realiza uma série de transformações nos dados para preparar para análise e modelagem preditiva. Aqui está um detalhamento passo-a-passo:

1. Configuração Inicial:
    a. Importa a biblioteca Pandas para manipulação de dados.
    b. Define listas de equipamentos e datas.
    c. Converte as datas para o formato datetime.
    d. Cria um dicionário mapeando equipamentos para suas respectivas datas.

2. Iteração sobre os Dados:

   a. Itera sobre cada equipamento no dicionário.
   b. Carrega os dados do arquivo CSV correspondente ao equipamento em um DataFrame.

3. Cálculo de "Manutencao":
   a. Converte a coluna "Data de Produção" para datetime.
   b. Calcula uma nova coluna "Manutencao" que representa os dias entre a data de produção e a data final da manutenção.
   c. Remove a coluna original "Data de Produção".

4. Ordenação e Cálculo de Somas Cumulativas:
   a. Ordena o DataFrame pela coluna "Manutencao".
   b. Calcula as somas cumulativas para as colunas "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada" e "Fator Un.", agrupando por "Manutencao".

5. Limpeza e Conversão de Dados Numéricos:
   a. Remove caracteres não numéricos da coluna "Consumo de massa no item em (Kg/100pcs)".
   b. Converte a coluna para numérica.
   c. Calcula as somas cumulativas para essa coluna, agrupando por "Manutencao".

6. Agrupamento e Reordenação:
   a. Agrupa o DataFrame por "Manutencao", selecionando o último valor de cada grupo.
   b. Reordena as colunas para colocar "Manutencao" no final.

7. Cálculo de Somas Cumulativas Totais:
   a. Calcula as somas cumulativas totais para as colunas "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada", "Fator Un." e "Consumo de massa no item em (Kg/100pcs)".

8. Reordenação Final e Exportação:
   a. Reordena as colunas novamente para colocar "Manutencao" no final.

b. Salva o DataFrame resultante em um novo arquivo CSV.

Observações:

a. O código assume que os arquivos CSV estão em um formato específico e contém as colunas mencionadas.
b. A data final da manutenção é definida como "2024-05-26" para todos os equipamentos.
c. O código inclui algumas linhas comentadas que podem ser usadas para exibir informações sobre os dados, como as primeiras linhas ou os tipos de dados das colunas.

Insights de Análise Exploratória (explo_data_ijXXX.ipynb)

A exploração de dados da injetora IJ-044 revelou diversos insights importantes sobre seu funcionamento e características. Primeiramente, observamos que não há registros duplicados no conjunto de dados, o que garante a integridade da análise. Em relação à produção, a injetora IJ-044 é exclusivamente utilizada para produção do "Cód. Un." "PC". O produto mais fabricado é o "SA04416", representando quase metade da produção total.

O composto mais utilizado na produção é o "P212/1", seguido pelos compostos "F420/306" e "N148/18". As estatísticas descritivas das variáveis numéricas mostram que a quantidade média produzida é de 518.761 unidades, com um desvio padrão de 294.603. A quantidade média de refugo é de 11.8391 unidades, com desvio padrão de 11.3862. A quantidade média de retrabalho é de 10 unidades, com desvio padrão de 1.08619. O fator unitário médio é de 2.65217, com desvio padrão de 7.28123.

Esses resultados fornecem um panorama do funcionamento da injetora IJ-044 e podem ser utilizados para orientar a escolha de algoritmos de machine learning e a construção de modelos preditivos.

Os dados foram extraídos do arquivo "mnt-oficial-IJ-044.csv", que contém informações sobre a produção, refugo, retrabalho, consumo de massa e manutenção da injetora IJ-044.

Análise Descritiva:

- Estatísticas Descritivas: As estatísticas descritivas foram calculadas para as variáveis numéricas, incluindo média, desvio padrão, mínimo, máximo e quartis.

- Duplicatas: Não foram encontradas entradas duplicadas no conjunto de dados.

Análise de Variáveis Categóricas:

- Distribuição: A distribuição das variáveis categóricas foi analisada, incluindo a contagem de valores únicos e a frequência de cada valor.
- Gráficos de Barras: Gráficos de barras foram criados para visualizar a distribuição das variáveis categóricas.

Principais Descobertas:

- Cód. Recurso: Todos os registros correspondem ao recurso "IJ-044", como esperado.
- Cód. Produto: O produto "SA04416" é o mais frequente, representando quase metade dos registros.
- Cód. Un.: Todos os registros utilizam a unidade "PC".
- Descrição da massa (Composto): O composto "P212/1" é o mais utilizado, seguido por "F420/306" e "N148/18".

A exploração de dados da injetora IJ-046 revelou informações relevantes sobre seu desempenho e características de produção. Primeiramente, verificou-se que não existem registros duplicados no conjunto de dados, garantindo a confiabilidade da análise. Observou-se também que todos os registros correspondem ao recurso "IJ-046", como esperado.

Em relação à produção, o produto "SA07320" é o mais fabricado, seguido de perto pelos produtos "SA05580" e "SA02961". As estatísticas descritivas das variáveis numéricas mostram que a quantidade média produzida é de 1322.17 unidades, com um desvio padrão de 5016.31, indicando uma grande variabilidade na produção. A quantidade média de refugo é de 30.0066 unidades, com desvio padrão de 24.2932. A quantidade média de retrabalho é de 10 unidades, com desvio padrão de 15.9608. O fator unitário médio é de 4.95017, com desvio padrão de 15.8852.

A análise exploratória dos dados da injetora IJ-117 revelou informações importantes sobre o processo de produção e consumo de material. Primeiramente, verificou-se que a quantidade total produzida foi de 276.484 unidades, enquanto a quantidade total refugada foi de 9.378 unidades, e não houve itens retrabalhados.

Observou-se também que o fator unitário variou entre 1 e 63, e que todos os itens produzidos pertencem ao código de unidade "PC".

Foram utilizados 12 tipos diferentes de compostos no processo de produção, sendo o "N148/18" o mais frequente. A correlação entre a quantidade produzida e a quantidade refugada foi de 0.095, enquanto a correlação entre a manutenção e a quantidade produzida foi de 0.084. Não houve correlação entre a quantidade produzida e a quantidade retrabalhada, nem entre a quantidade refugada e a quantidade retrabalhada. Observou-se uma correlação negativa de -0.169 entre a manutenção e o consumo de massa.

A amplitude do consumo de massa variou de 0.48 a 20.172 Kg/100pcs. As estatísticas descritivas mostram que a quantidade média produzida foi de 861 unidades, com desvio padrão de 401, e a quantidade média de refugo foi de 29 unidades, com desvio padrão de 42. Os histogramas indicam que a quantidade produzida tem uma distribuição assimétrica à direita, enquanto a quantidade refugada e retrabalhada são fortemente assimétricas à direita, concentradas em zero.

O gráfico de dispersão entre a quantidade produzida e a quantidade refugada mostra uma correlação positiva fraca. O box plot do consumo de massa revela que a distribuição é assimétrica à direita, com uma mediana em torno de 5 e vários outliers na extremidade superior. Esses resultados fornecem uma visão abrangente do processo de produção da injetora IJ-117 e podem ser utilizados para orientar a tomada de decisões e a otimização do processo.

Este relatório apresenta uma análise exploratória detalhada dos dados da injetora IJ-117, utilizando dados extraídos do arquivo "mnt-oficial-IJ-117.csv". Portanto, é possível aplicar a mesma análise a todos os dados disponibilizados após a transformação de variáveis, com apenas algumas modificações nos arquivos em Python compartilhados. O objetivo principal desta análise é obter uma compreensão abrangente do processo de produção, identificar tendências potenciais e descobrir quaisquer padrões subjacentes nos dados.

Resumo das Quantidades:

- Total de Unidades Produzidas: 276.484
- Total de Unidades Rejeitadas: 9.378
- Total de Unidades Retrabalhadas: 0

Esses números fornecem uma visão geral básica da produção e da extensão dos problemas de qualidade encontrados durante o processo. A ausência de unidades

retrabalhadas sugere que os itens rejeitados são descartados ou corrigidos sem documentação formal de retrabalho.

Valores Únicos:

- Fator Un.:
- Cód. Un.: ['PC']
- Descrição da massa (Composto): ['N148/18', 'F403/32', 'F424/40', 'F420/191', '5316/2', '5315/10', 'P212/1', 'P250/14', 'N146/9', 'N-142/67', 'F444/1', 'F420/95'] O "Fator Un." (Fator Unitário) exibe vários valores distintos, cujo significado requer investigação adicional. Todos os itens produzidos pertencem ao código de unidade "PC", indicando um tipo de unidade padronizado. O processo de produção utiliza 12 tipos diferentes de compostos, sendo o "N148/18" o mais prevalente.

Análise de Correlação:

- Correlação entre Qtd. Produzida (Quantidade Produzida) e Qtd. Refugada (Quantidade Rejeitada): 0.095
- Correlação entre Qtd. Produzida e Qtd. Retrabalhada (Quantidade Retrabalhada): NaN (Não aplicável/Sem correlação)
- Correlação entre Qtd. Refugada e Qtd. Retrabalhada: NaN (Não aplicável/Sem correlação)

A fraca correlação positiva (0.095) entre a quantidade produzida e a quantidade rejeitada sugere uma leve tendência de aumento das taxas de rejeição à medida que o volume de produção aumenta. Isso pode indicar problemas potenciais com a estabilidade do processo ou controle de qualidade em níveis mais altos de produção. A falta de correlação entre a quantidade de produção e a quantidade de retrabalho, bem como entre a quantidade rejeitada e a quantidade de retrabalho, apoia ainda mais a observação de que o retrabalho não é formalmente documentado.

Variação no Consumo de Massa:

- Intervalo: (0,48, 20,172)

Esse intervalo indica variabilidade significativa no consumo de massa por 100 unidades produzidas. Uma análise mais aprofundada é necessária para entender os fatores que contribuem para essa variação, como diferentes tipos de compostos ou parâmetros do processo.

Estatísticas Descritivas:

A tabela de estatísticas descritivas revela que a quantidade média de produção (Qtd. Produzida) é de 861 unidades, com um desvio padrão de 401. Isso destaca a variabilidade substancial nas quantidades de produção, sugerindo inconsistências potenciais no processo. A quantidade média rejeitada (Qtd. Refugada) é consideravelmente menor, com uma média de 29 e um desvio padrão de 42. A ausência de itens retrabalhados (Qtd. Retrabalhada) é confirmada pelos valores zero em todas as estatísticas.

Histogramas:

Os histogramas representam visualmente a distribuição das quantidades produzidas, rejeitadas e retrabalhadas. O histograma para Qtd. Produzida exibe uma distribuição assimétrica à direita, indicando que a maioria das execuções de produção produz quantidades abaixo da média. Os histogramas para Qtd. Refugada e Qtd. Retrabalhada são fortemente assimétricos à direita, concentrados em zero, refletindo a baixa rejeição e a ausência de retrabalho.

Gráfico de Dispersão:

O gráfico de dispersão comparando Qtd. Produzida e Qtd. Refugada reforça visualmente a fraca correlação positiva entre essas variáveis. A distribuição dispersa dos pontos sugere que outros fatores além da quantidade de produção influenciam as taxas de rejeição.

Box Plot de Consumo de Massa:

O box plot para consumo de massa (Consumo de massa no item em (Kg/100pcs)) ilustra uma distribuição assimétrica à direita, com uma mediana em torno de 5 e vários outliers na extremidade superior. Isso indica que, embora a maioria das execuções de produção tenha consumo moderado de massa, algumas instâncias exibem consumo excepcionalmente alto, justificando investigação adicional.

A análise exploratória de dados da injetora IJ-117 fornece insights valiosos sobre o processo de produção, destacando as características principais e potenciais áreas de melhoria. A análise revela variabilidade nas quantidades de produção, uma fraca correlação positiva entre as quantidades de produção e rejeição e variação significativa no consumo de massa. Essas descobertas podem informar a tomada de decisões e orientar os esforços para otimizar o processo de produção, reduzir o desperdício e

melhorar a eficiência geral. Além da análise inicial, foram realizadas investigações adicionais para explorar a relação entre manutenção e outras variáveis, como quantidade de produção, quantidade rejeitada, quantidade retrabalhada e consumo de massa. Essas análises visam identificar potenciais ligações entre as atividades de manutenção e os resultados da produção.

Valores Únicos de Manutenção:

A variável "Manutencao" representa os dias até a manutenção. Possui 184 valores únicos, variando de 1 a 355 dias.

Correlação entre Manutencao e outras variáveis:

- Correlação entre Manutencao e Qtd. Produzida: 0,084
- Correlação entre Manutencao e Qtd. Refugada: 0,012
- Correlação entre Manutencao e Qtd. Retrabalhada: NaN (Não aplicável/Sem correlação)
- Correlação entre Manutencao e Consumo de massa no item em (Kg/100pcs): -0,169

Essas correlações sugerem que há uma fraca relação positiva entre Manutencao e Qtd. Produzida e uma relação positiva muito fraca entre Manutencao e Qtd. Refugada. Não há correlação entre Manutencao e Qtd. Retrabalhada. Curiosamente, há uma fraca correlação negativa entre Manutencao e Consumo de massa no item em (Kg/100pcs), o que pode indicar que as máquinas consomem menos massa à medida que se aproximam da data de manutenção.

Estatísticas descritivas para Descrição da massa (Composto) específica:

- Estatísticas descritivas para Descrição da massa (Composto) = N148/18:
  - Média Qtd. Produzida: 1058,9, dp: 290,751
  - Média Qtd. Refugada: 21,1905, dp: 15,867
  - Média Qtd. Retrabalhada: 10, dp: 0

Estatísticas descritivas para Descrição da massa (Composto) = F420/95:

  - Média Qtd. Produzida: 699,5, dp: 751,655
  - Média Qtd. Refugada: 9,5, dp: 6,36396
  - Média Qtd. Retrabalhada: 10, dp: 0

Essas estatísticas mostram que o composto "N148/18" tem uma quantidade média de produção maior e uma quantidade média rejeitada maior em comparação com o composto "F420/95".

Gráficos de Dispersão:

- Gráfico de dispersão comparando Manutencao e Qtd. Produzida: O gráfico mostra uma distribuição dispersa de pontos, com uma leve tendência positiva. Isso confirma visualmente a fraca correlação positiva entre essas variáveis.
- Gráfico de dispersão comparando Manutencao e Consumo de massa no item em (Kg/100pcs): O gráfico mostra uma distribuição dispersa de pontos, com uma leve tendência negativa. Isso confirma visualmente a fraca correlação negativa entre essas variáveis.

Observações Gerais:

- A análise exploratória de dados é uma etapa crucial na compreensão das características dos dados e na construção de modelos preditivos eficazes.
- Os insights obtidos da EDA podem apoiar a tomada de decisões, a otimização de processos e o desenvolvimento de intervenções direcionadas para melhorar a eficiência da produção e a qualidade do produto.

Modelagem e Aprendizado de Máquinas:

Dado o objetivo de prever falhas em injetoras de borracha, podemos utilizar algoritmos de machine learning para criar um modelo preditivo. A escolha do algoritmo depende das características dos dados e do objetivo específico da previsão. Alguns algoritmos adequados para este caso incluem:

1. Regressão Linear:

A regressão linear é um algoritmo simples e amplamente utilizado para prever um valor numérico contínuo. Neste caso, poderíamos utilizá-la para prever o tempo restante até a próxima falha, com base nas variáveis de entrada, como quantidade produzida, quantidade refugada, quantidade retrabalhada e consumo de massa. A regressão linear é fácil de interpretar e implementar, mas pode não ser a melhor opção se a relação entre as variáveis de entrada e o tempo até a falha for complexa e não linear.

2. Árvores de Decisão:

Árvores de decisão são algoritmos que criam um modelo em forma de árvore para prever um valor discreto ou contínuo. No contexto da previsão de falhas, as árvores de decisão podem ser utilizadas para classificar as injetoras em diferentes categorias de risco de falha, com base nas variáveis de entrada. As árvores de decisão são fáceis de interpretar e podem lidar com relações complexas entre as variáveis, mas podem ser propensas a overfitting, ou seja, o modelo se ajusta muito aos dados de treinamento e não generaliza bem para novos dados.

3. Random Forest:

Random Forest é um algoritmo que combina várias árvores de decisão para criar um modelo mais robusto e preciso. Ele é menos propenso a overfitting do que as árvores de decisão individuais e pode lidar com dados de alta dimensionalidade. No caso da previsão de falhas, o Random Forest pode ser utilizado para prever a probabilidade de falha de uma injetora em um determinado período de tempo, com base nas variáveis de entrada.

4. Support Vector Machines (SVM):

SVM é um algoritmo que busca encontrar o hiperplano que melhor separa os dados em diferentes classes. No contexto da previsão de falhas, o SVM pode ser utilizado para classificar as injetoras em diferentes categorias de risco de falha, com base nas variáveis de entrada. O SVM é eficaz em problemas de classificação com alta dimensionalidade e pode lidar com relações complexas entre as variáveis, mas pode ser sensível à escolha do kernel e dos parâmetros.

Predição de Falhas em Injetoras de Borracha (prediction_01.ipynb)

Este relatório visa apresentar uma análise detalhada dos métodos de Machine Learning utilizados em um projeto de previsão de falhas em injetoras de borracha. O objetivo principal é construir um modelo preditivo capaz de estimar o tempo restante até a próxima manutenção ("Manutencao"), auxiliando na otimização do processo e evitando falhas inesperadas.

Dados e Pré-processamento:

Os dados utilizados neste projeto foram extraídos de diversos arquivos CSV, cada um contendo informações sobre a produção de uma injetora específica, como

quantidade produzida, quantidade de refugo, quantidade retrabalhada, tipo de composto utilizado, entre outros.

Antes de aplicar os algoritmos de Machine Learning, os dados foram pré-processados. Primeiramente, os conjuntos de dados de diferentes injetoras ("mnt-oficial-IJ-XXX.csv") foram combinados em um único DataFrame, consolidando as informações para análise. Em seguida, as variáveis categóricas, como "Cód. Produto", "Descrição da massa (Composto)" e "Cód. Recurso", foram codificadas utilizando One-Hot Encoding. Esse método transforma cada categoria em uma nova coluna binária, permitindo que o modelo utilize essas informações na previsão.

Engenharia de Recursos:

A etapa de engenharia de recursos é crucial para o sucesso de qualquer projeto de Machine Learning. Neste projeto, foram realizadas as seguintes etapas:

- Criação de Variáveis Cumulativas: Variáveis cumulativas foram criadas para "Qtd. Produzida", "Qtd. Refugada", "Qtd. Retrabalhada", "Fator Un." e "Consumo de massa no item em (Kg/100pcs)". Essas variáveis fornecem informações sobre o histórico de produção e podem ser úteis para identificar tendências e padrões ao longo do tempo.
- Transformação de Datas: A coluna "Data de Produção" foi convertida para o tipo de dado datetime e utilizada para calcular a variável "Manutencao", que representa o número de dias até a próxima manutenção. Essa transformação permite que o modelo utilize informações temporais na previsão.
- Codificação One-Hot: As variáveis categóricas "Cód. Produto", "Descrição da massa (Composto)" e "Cód. Recurso" foram codificadas utilizando One-Hot Encoding. Esse método cria novas colunas binárias para cada categoria, permitindo que o modelo utilize essas informações na previsão.

Seleção de Modelos:

A seleção dos modelos de Machine Learning foi baseada na natureza da variável alvo ("Manutencao"), que é numérica e contínua. Os seguintes modelos foram selecionados para a análise inicial:

- Regressão Linear: Um modelo simples e amplamente utilizado para prever variáveis contínuas.
- Random Forest: Um modelo ensemble que combina múltiplas árvores de decisão para melhorar a precisão da previsão.

- Decision Tree: Um modelo que cria uma estrutura de árvore para representar as decisões e suas consequências.
- XGBoost: Um algoritmo de boosting que combina múltiplas árvores de decisão de forma sequencial, com cada árvore corrigindo os erros da anterior.

Treinamento e Avaliação dos Modelos:

Após a preparação dos dados, a variável "Manutencao" foi definida como a variável alvo (y), representando o tempo restante até a próxima manutenção. As demais colunas numéricas, exceto "Cód. Un.", foram utilizadas como variáveis preditoras (X). Os dados foram então divididos em conjuntos de treinamento (80%) e teste (20%) utilizando a função train_test_split, garantindo que o modelo seja avaliado com dados não utilizados no treinamento.

Cada modelo foi treinado com os dados de treinamento e, em seguida, testado com os dados de teste, utilizando métricas como R^2 e MSE (Erro Quadrático Médio) para avaliar a qualidade da previsão. O modelo de Regressão Linear, por exemplo, obteve um R^2 de 0.985 nos dados de teste, indicando um bom ajuste aos dados.

Comparação e Resultados dos Modelos:

A comparação dos modelos baseados em árvores (Random Forest, Decision Tree e XGBoost) mostrou que o XGBoost apresentou o melhor desempenho, com o menor MSE e o maior R^2. Isso sugere que o XGBoost, um algoritmo de boosting que combina múltiplas árvores de decisão, é mais eficaz na captura de padrões complexos nos dados e na previsão do tempo restante até a manutenção.

Importância das Variáveis:

A análise da importância das variáveis para os modelos Decision Tree, Random Forest e Gradient Boosting revelou que a variável "Cód. Ordem" é a mais importante para a previsão. Esse resultado indica que o código da ordem de produção tem uma forte influência na necessidade de manutenção, possivelmente refletindo diferenças nos tipos de produtos ou nas configurações das máquinas para cada ordem.

Conclusões Iniciais:

A aplicação de métodos de Machine Learning permitiu a construção de modelos preditivos com bom desempenho para estimar o tempo restante até a próxima manutenção em injetoras de borracha. O XGBoost se destacou como o melhor modelo,

e a variável "Cód. Ordem" foi identificada como a mais importante para a previsão. Esses resultados podem auxiliar na tomada de decisões estratégicas para otimizar o processo de produção e evitar falhas inesperadas nas máquinas.

Recomendações:

Com base nos resultados da análise, as seguintes recomendações podem ser feitas:

- Monitoramento da Variável "Cód. Ordem": Como a variável "Cód. Ordem" foi identificada como a mais importante para a previsão, é crucial monitorar essa variável e seus efeitos na necessidade de manutenção.
- Coleta de Dados Adicionais: A coleta de dados adicionais sobre as máquinas, como temperatura, vibração e pressão, pode melhorar a precisão dos modelos preditivos.
- Implementação do Modelo XGBoost: O modelo XGBoost, por ter apresentado o melhor desempenho, deve ser implementado em um sistema de monitoramento em tempo real para prever a necessidade de manutenção e gerar alertas para evitar falhas inesperadas.
- Validação Contínua do Modelo: O modelo deve ser continuamente validado e atualizado com novos dados para garantir sua precisão e eficácia ao longo do tempo.

Considerações Finais:

A aplicação de Machine Learning neste projeto demonstrou o potencial da técnica para prever falhas em equipamentos industriais e auxiliar na otimização do processo de produção. A análise detalhada dos dados, a seleção adequada dos modelos e a interpretação dos resultados são cruciais para o sucesso de projetos de Machine Learning.

Relatório Detalhado de Análise de Dados de Produção Industrial e Previsão de Manutenção utilizando Hyperparametros (prediction_02.ipynb)

Introdução

Este relatório detalhado descreve a análise de dados de produção industrial com o objetivo de prever a necessidade de manutenção em equipamentos. O conjunto de dados utilizado, proveniente de múltiplos arquivos CSV, contém informações

abrangentes sobre o processo produtivo, incluindo quantidade produzida, quantidade refugada, quantidade retrabalhada, consumo de massa e outros atributos relevantes. A análise foi conduzida utilizando técnicas avançadas de aprendizado de máquina, com foco em modelos de regressão e árvores de decisão. O objetivo principal é construir um modelo preditivo capaz de antecipar a necessidade de manutenção, otimizando o processo produtivo e minimizando perdas.

Metodologia

A metodologia empregada na análise dos dados e previsão da necessidade de manutenção compreende as seguintes etapas:

Coleta e Preparação dos Dados:

Inicialmente, os dados foram coletados de múltiplos arquivos CSV e consolidados em um único DataFrame utilizando a biblioteca Pandas. Em seguida, foi realizado um pré-processamento dos dados, incluindo a conversão de variáveis categóricas em numéricas através da técnica de one-hot encoding.

Treinamento e Avaliação dos Modelos:

Os dados foram divididos em conjuntos de treinamento e teste, utilizando 80% dos dados para treinamento e 20% para teste. Diversos modelos de aprendizado de máquina foram treinados e avaliados, incluindo:

- Regressão Linear: Um modelo linear que busca encontrar a melhor reta que representa a relação entre as variáveis preditoras e a variável alvo.
- Random Forest: Um modelo de árvore de decisão que combina múltiplas árvores para produzir previsões mais robustas e precisas.
- Árvore de Decisão: Um modelo que utiliza uma estrutura de árvore para representar as decisões e suas possíveis consequências.
- XGBoost: Um modelo de árvore de decisão que utiliza algoritmos de boosting para melhorar a precisão das previsões.

O desempenho dos modelos foi avaliado utilizando as seguintes métricas:

- Erro Quadrático Médio (EQM): Mede a média dos quadrados das diferenças entre os valores previstos e os valores reais.
- R-quadrado: Mede a proporção da variância na variável dependente que é explicada pelas variáveis independentes.

- Erro Absoluto Médio (EAM): Mede a média dos valores absolutos das diferenças entre os valores previstos e os valores reais.

Ajuste de Hiperparâmetros:

Os hiperparâmetros dos modelos foram ajustados utilizando o método RandomizedSearchCV, que permite explorar aleatoriamente diferentes combinações de hiperparâmetros para encontrar a melhor configuração para cada modelo.

Seleção do Melhor Modelo:

O melhor modelo foi selecionado com base na métrica R-quadrado, que indica a capacidade do modelo de explicar a variabilidade dos dados. O modelo com o maior valor de R-quadrado foi considerado o mais adequado para a previsão da necessidade de manutenção.

Visualização dos Resultados:

Os resultados da análise foram visualizados utilizando gráficos de dispersão e mapas de calor. Os gráficos de dispersão permitem analisar a relação entre as variáveis preditoras e a variável alvo, enquanto os mapas de calor permitem visualizar o impacto dos hiperparâmetros no desempenho dos modelos.

Resultados Detalhados

Desempenho dos Modelos

A tabela abaixo apresenta o desempenho dos modelos de aprendizado de máquina treinados e avaliados:

Modelo	EQM	R-quadrado	EAM
Regressão Linear	1094.23	0.9800	24.56
Random Forest	12.69	0.9991	1.95

Árvore de Decisão	20.62	0.9985	2.41
XGBoost	28.01	0.9979	3.68

Análise do Modelo Random Forest:

O modelo Random Forest apresentou o melhor desempenho, com um EQM de 12.69, um R-quadrado de 0.9991 e um EAM de 1.95. O modelo foi capaz de explicar 99.91% da variabilidade dos dados, indicando uma alta capacidade preditiva.

Ajuste de Hiperparâmetros:

O ajuste de hiperparâmetros utilizando o RandomizedSearchCV permitiu encontrar a melhor configuração para o modelo Random Forest, com os seguintes hiperparâmetros:

- n_estimators: 797
- max_depth: None
- min_samples_split: 2
- min_samples_leaf: 3
- max_features: 'sqrt'
- bootstrap: False

Visualização dos Resultados:

Os gráficos de dispersão e mapas de calor gerados permitem visualizar a relação entre as variáveis preditoras e a variável alvo, além de analisar o impacto dos hiperparâmetros no desempenho do modelo Random Forest.

Conclusões

A análise detalhada dos dados de produção industrial utilizando técnicas de aprendizado de máquina demonstrou ser uma ferramenta poderosa para prever a necessidade de manutenção em equipamentos. O modelo Random Forest, após o ajuste de hiperparâmetros, apresentou o melhor desempenho, com alta capacidade preditiva e robustez. A utilização desse modelo pode auxiliar na otimização do processo produtivo, minimizando perdas e aumentando a eficiência.

Próximos Passos e Recomendações

Os próximos passos da análise incluem a exploração de outros modelos de aprendizado de máquina, como redes neurais, e a utilização de técnicas de engenharia de recursos para melhorar ainda mais o desempenho dos modelos. Além disso, a implantação do modelo Random Forest em um ambiente de produção permitirá realizar previsões em tempo real, auxiliando na tomada de decisão e otimização do processo produtivo.

Recomenda-se a utilização do modelo Random Forest para prever a necessidade de manutenção em equipamentos, com base nos dados de produção industrial analisados. A equipe de produção industrial deve ser treinada para utilizar o modelo e interpretar os resultados, a fim de tomar decisões mais assertivas e eficientes.

Este relatório detalhado fornece uma análise abrangente dos dados de produção industrial e da capacidade preditiva do modelo Random Forest. As informações e visualizações apresentadas podem auxiliar na tomada de decisão e otimização do processo produtivo, contribuindo para o aumento da eficiência e redução de perdas.