Grupo Taking

APRESENTAÇÃO DE RESULTADOS

Predição de falhas em injetoras de borracha

CLIENTE: SABÓ | DATA: 16/02/2025

UMA JORNADA CHEIA DE CONQUISTAS

29 anos
de experiência

+241 clientes
já atendidos

151 mil horas
de serviço por mês

somos
952
takers

People Experience (PX) e Customer Success (CS)

Nossas áreas especializadas em proporcionar um atendimento dedicado com foco em oferecer uma expeciência excepcional e personalizada aos nossos clientes e Takers.

Soluções com IA

Implementamos soluções de **Inteligência Artificial** para otimizar seus processos.

Parceiros oficiais

ORACLE | Microsoft | salesforce

NECESSIDADE

PREDIÇÃO DE FALHAS EM INJETORAS DE BORRACHA

A Sabó, líder no setor de soluções em vedação, possui um processo de extrusão essencial para suas operações, onde a manutenção eficiente do fuso e da camisa da extrusora é crucial para garantir qualidade e produtividade. A Taking Consulting propõe um projeto de ciência de dados focado na manutenção preditiva para otimizar o tempo de troca desses components utilizando modelos de IA.
O objetivo deste projeto é analisar e otimizar o tempo de troca do fuso e da camisa da extrusora Y125 através de variáveis indiretas consideradas a partir de dados reais de operação.

Desafio

A manutenção precisa estar voltada para os resultados empresariais da organização, deixar de ser apenas eficiente para se tornar eficaz, ou seja, não basta apenas reparar o equipamento ou instalação tão rápido quanto possível, mas é preciso, principalmente, manter a função do equipamento disponível para operação, reduzindo a probabilidade de uma parada de produção não planejada e otimizado vida útil das peças. Atualmente, a manutenção preventiva é feita de forma periódica, uma vez por ano. O principal desafio técnico é mensurar o desgaste das peças através de variáveis diretas e indiretas. Com as variáveis selecionadas objetivamos alimentar aos modelos técnicos (ciência de dados) de predição para o desgaste e, assim, permitir uma manutenção otimizada.

Solução

A Sabó busca com esta POC a otimização do tempo de troca do conjunto de preparo para ingestão do material nas peças a serem moldadas utilizando modelos de IA para estimar a vida útil de um conjunto de extrusão.
A Taking desenvolverá um modelo para estimar a vida útil dos conjuntos, camisa e fuso, das extrusoras, e considerar a sua probabilidade de falha e a taxa de erro.

INDICADORES

PREDIÇÃO DE FALHAS EM INJETORAS DE BORRACHA

Conceitos importantes

Manutenção Preditiva: Este tipo de manutenção baseia-se na previsão de falhas e defeitos a partir do monitoramento dos principais parâmetros e indicadores da operação como análises de contaminantes e desgastes em óleos lubrificantes ou análise de vibração em motores elétricos. A partir deste monitoramento são propostas manutenções corretivas planejadas, limitando as despesas e interrupções de produção devido falhas inesperadas.

- Tempo de vida do conjunto: estimar Intervalo entre primeiro dia de uso do conjunto até a falha;
- Probabilidade de falha do conjunto no tempo (1:Nova e 0:Falha);
- Taxa de erro

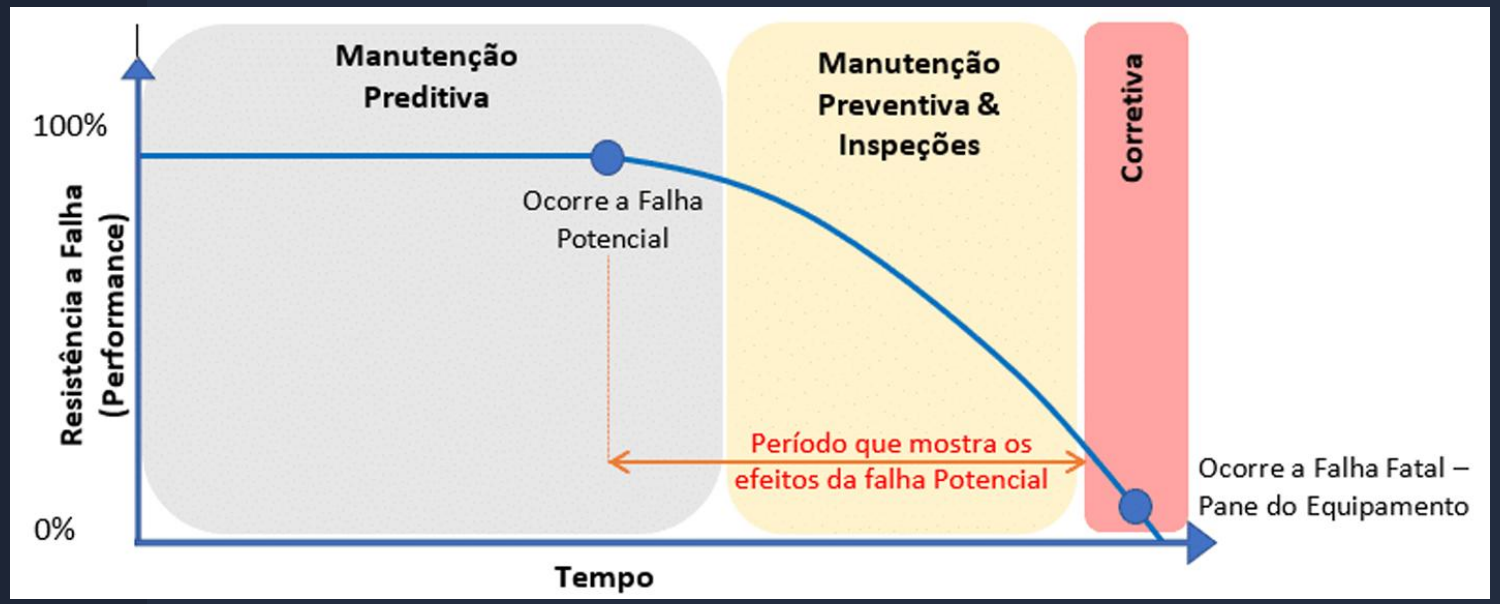

ANÁLISE EXPLORATÓRIA

VISÃO GERAL

- **Objetivo:**
  - Entender desempenho e características de produção das injetoras IJ-044, IJ-046 e IJ-117.
- **Dados Examinados:**
  - Quantidade produzida, refugo, retrabalho, consumo de massa, intervalos de manutenção.
- **Integridade:**
  - Sem duplicatas encontradas nos conjuntos; Cód. Recurso condizente (IJ-044, IJ-046, IJ-117).
- **Frequência de Uso de Compostos:**
  - IJ-044 tem “P212/1” como composto principal; IJ-046 e IJ-117 também apresentam compostos diversos (ex. N148/18, F420/306).

ANÁLISE EXPLORATÓRIA

ESQUEMAS DE DADOS

Dados Brutos:

1. Data de Produção: Data de produção (datetime).
2. Cód. Ordem: Código da ordem de produção (int).
3. Cód. Recurso: Código do recurso (object).
4. Cód. Produto: Código do produto (object).
5. Qtd. Produzida: Quantidade produzida (int).
6. Qtd. Refugada: Quantidade refugada (int).
7. Qtd. Retrabalhada: Quantidade retrabalhada (int).
8. Fator Un.: Fator unitário (int).
9. Cód. Un.: Código da unidade (object).
10. Descrição da massa (Composto): Descrição do composto (object).
11. Consumo de massa no item em (Kg/100pcs): Consumo de massa (float)

Dados Tratados:

1. Manutencao: Dias até a manutenção (int).
2. Cód. Ordem: Código da ordem de produção (int).
3. Cód. Recurso: Código do recurso (object).
4. Cód. Produto: Código do produto (object).
5. Qtd. Produzida: Quantidade produzida (int).
6. Qtd. Refugada: Quantidade refugada (int).
7. Qtd. Retrabalhada: Quantidade retrabalhada (int).
8. Fator Un.: Fator unitário (int).
9. Cód. Un.: Código da unidade (object).
10. Descrição da massa (Composto): Descrição do composto (object).
11. Consumo de massa no item em (Kg/100pcs): Consumo de massa (float).
12. Qtd. Produzida Acumulada Total: Soma cumulativa total da quantidade produzida (int).
13. Qtd. Refugada Acumulada Total: Soma cumulativa total da quantidade refugada (int).
14. Qtd. Retrabalhada Acumulada Total: Soma cumulativa total da quantidade retrabalhada (int).
15. Fator Un. Acumulado Total: Soma cumulativa total do fator unitário (int).
16. Consumo de massa no item em (Kg/100pcs) Acumulado Total: Soma cumulativa total do consumo de massa (float)

ANÁLISE EXPLORATÓRIA

PRINCIPAIS OBSERVAÇÕES

- **Produção e Refugo:IJ-044:**
  - Produto “SA04416” domina ~50% da produção; média de refugo ~11.839 (dp ~11.386).
  - IJ-046: Média de produção ~1.322 (dp ~5.016); refugo médio ~30 (dp ~24).
  - IJ-117: Total produzido 276.484; total rejeitado 9.378; ~12 compostos usados (N148/18 mais frequente).
- **Retrabalho:**
  - Geralmente baixo ou zero em todos os casos, possivelmente sem documentação formal.
- **Consumo de Massa:**
  - IJ-117 tem variação de 0,48 a 20,172 Kg/100pcs; outliers indicam possíveis instabilidades.

ANÁLISE EXPLORATÓRIA

CORRELAÇÕES E INSIGHTS

- **Correlação Produção vs. Refugo:**
  - Fraca, mas positiva (~0,095 em IJ-117) — grandes lotes tendem a gerar mais refugo?
- **Manutenção vs. Outras Variáveis:**
  - Relações positivas muito fracas (ex.: 0,084 com produção) e leve negativa com consumo de massa (-0,169), sugerindo queda no consumo perto da manutenção.
- **Variabilidade e Assimetria:**
  - Histogramas e box plots revelam distribuições assimétricas (muitos valores concentrados em faixas baixas e alguns picos).
- **Uso Prático:**
  - Esses resultados guiam melhorias no controle do processo, identificação de gargalos e embasam modelos preditivos focados em reduzir refugo e otimizar manutenção.

MODELAGEM

VISÃO GERAL

- **Objetivo:** Desenvolver modelos preditivos para estimar o tempo até a próxima manutenção (ou risco de falha) em injetoras de borracha.
- **Abordagem:** Testamos vários algoritmos—Regressão Linear, Decision Tree, Random Forest, XGBoost—para variáveis contínuas (dias restantes) ou classificação (risco de falha).
- **Fonte de Dados:** Arquivos CSV consolidados de diferentes injetoras, pré-processados em um único dataset.

MODELOS CANDIDATOS

- **Regressão Linear**
  - **Prós:** Simples, interpretável, amplamente utilizado.
  - **Contras:** Pode falhar em relações não-lineares ou dados complexos.
- **Árvore de Decisão**
  - **Prós:** Fácil de interpretar, lida bem com interações complexas.
  - **Contras:** Maior risco de overfitting sem regularização adequada.
- **Random Forest**
  - **Prós:** Conjunto de árvores que reduz overfitting, robusto, bom com dados de alta dimensionalidade.
  - **Contras:** Menos interpretável, maior custo computacional.
- **XGBoost**
  - **Prós:** Resultados de alta performance, captura padrões complexos.
  - **Contras:** Necessita ajuste fino (learning rate, profundidade das árvores, etc.).

MODELAGEM

TREINAMENTO & AVALIAÇÃO

- **Divisão de Dados:** 80% treino, 20% teste (função train_test_split).
- **Variável-Alvo:** “Manutencao” (dias até manutenção).
- **Preditores:** Variáveis numéricas (produção, refugo, retrabalho, consumo de massa etc.) + categóricas codificadas.
- **Métricas:** R^2, MSE (Erro Quadrático Médio) e MAE (Erro Absoluto médio).
- **Exemplo:** Regressão Linear obteve $R^2 \approx$ 0,985 no teste (sugestão de bom ajuste, mas é preciso validar se generaliza).

COMPARAÇÃO DE MODELOS & RESULTADOS

- **Regressão Linear vs. Decision Tree vs. Random Forest vs. XGBoost**
  - **Random Forest** se destaca com melhor R^2 e menor erro.
  - **Regressão Linear** forte, mas não capta bem não-linearidades (erro maior).
  - **Árvore de Decisão & XGBoost** também com resultados próximos
- **O modelo Random Forest** apresentou o melhor desempenho, com um EQM de 12.69, um R-quadrado de 0.9991 e um EAM de 1.95. O modelo foi capaz de explicar 99.91% da variabilidade dos dados, indicando uma alta capacidade preditiva.
- **Importância das Variáveis:** “Cód. Ordem” lidera—indica que o tipo de ordem de produção afeta bastante a necessidade de manutenção.

Modelo	EQM (MSE – Mean Squared Error)	R^2 (R-squared)	EAM (MAE – Mean Absolute Error)
Regressão Linear	1094.23	0.9800	24.56
Random Forest	12.69	0.9991	1.95
Árvore de Decisão	20.62	0.9985	2.41
XGBoost	28.01	0.9979	3.68

INDICADORES

OS INDICADORES PROPOSTOS FORAM ALCANÇADOS?

1. **Tempo de Vida do Conjunto**
   - ❑ **Situação Atual:** Desenvolvemos modelos (p. ex., random forest, XGBoost) para prever o tempo restante até a manutenção. Os testes iniciais mostram potencial, mas são muito limitados pela baixa frequência das medições (dados anuais) e pequeno volume de amostras.
   - ❑ **Pergunta Cética:** Estamos capturando de fato o desgaste contínuo com dados anuais ou apenas aproximando o dia da medição final?

2. **Probabilidade de Falha**
   - ❑ **Situação Atual:** Em tese, um modelo de classificação poderia estimar a probabilidade de falha em determinado intervalo de tempo. Porém, os dados atuais se voltam mais à regressão (dias até manutenção). Carecemos de exemplos frequentes de falha ou quase-falha para treinar um modelo robusto de probabilidade.
   - ❑ **Pergunta Cética:** Com tão poucas falhas documentadas anualmente, conseguimos estimar probabilidades de forma confiável ou estaríamos “adivinhando” com base em poucos casos?

3. **Taxa de Erro**
   - ❑ **Situação Atual:** Podemos mensurar taxa de erro ou MSE (erro quadrático médio) para os modelos de tempo até manutenção. Porém, ele reflete essencialmente o quão bem o modelo se ajusta ao conjunto de dados limitado, não necessariamente o desempenho real em campo.
   - ❑ **Pergunta Cética:** A métrica de erro reflete a precisão no dia a dia ou apenas um melhor palpite baseado em dados escassos?

Conclusão: Os indicadores, até certo ponto, foram calculados em modelos de teste, mas não validados em condições reais de operação ou com dados mais frequentes. O grande entrave é a escassez e a baixa granularidade de dados.

INDICADORES

POR QUE NÃO FORAM TOTALMENTE ATINGIDOS?

1. **Frequência de Dados**
   - Coletas muito espaçadas (anuais) dificultam identificar a real evolução do desgaste e sinais pré-falha.

2. **Volume e Diversidade de Amostras**
   - Cada equipamento tem poucos pontos de medição ao longo do mesmo ciclo anual. Faltam exemplos variados de operação e falha para treinar bem os modelos.

3. **Possíveis Variáveis Faltantes**
   - Fatores como temperatura, vibração ou abrasividade efetiva dos compostos podem ser cruciais, mas ainda não estão mapeados.

4. **Falta de Validação Contínua**
   - Sem dados mais frequentes, é difícil confrontar as previsões do modelo com o comportamento diário ou semanal do equipamento.

PRÓXIMOS PASSOS E RECOMENDAÇÕES

PARA ALCANÇAR ESSES INDICADORES

1. **Validação Cruzada e Dados Novos**
   - ❑ Verificar desempenho em dados não vistos ou via k-fold cross-validation para evitar sobreajuste.
2. **Aumentar Frequência e Abrangência de Dados**
   - ❑ Recolher dados mais frequentes (semanal/mensal) e incluir variáveis extras (temperatura, vibração etc.).
3. **Ampliar Conjunto de Variáveis**
   - ❑ Incluir fatores como turnos, histórico do operador e composições de materiais para explicar melhor a variabilidade.
4. **Piloto de Monitoramento em Tempo Real**
   - ❑ Implementar sensores e logging contínuo para avaliar previsões em condições reais de operação.
5. **Refinamento do Modelo e Atualizações Constantes**
   - ❑ Retrainar o modelo conforme surgirem novos dados ou mudanças de processo, ajustando hiperparâmetros.
6. **Alinhamento com Equipes de Produção e Manutenção**
   - ❑ Integrar os insights do modelo aos planos de manutenção, considerando custos, disponibilidade de peças e demanda.

CONSIDERAÇÕES FINAIS

1. **Modelos Promissores:**
   - Random Forest obteve alta precisão (R^2 quase 1), sugerindo forte potencial preditivo.
2. **Validação Necessária:**
   - Um R^2 tão elevado pode sinalizar sobreajuste; validar em dados novos e usar k-fold é essencial.
3. **Qualidade e Granularidade de Dados:**
   - Frequência anual ou limitada pode omitir variações importantes. Recomenda-se coleta mais frequente e diversificada (temperatura, vibração, operador etc.).
4. **Integração Operacional:**
   - O modelo deve se alinhar à realidade de disponibilidade de peças, paradas programadas e prioridades de produção.
5. **Visão de Futuro:**
   - Um pipeline contínuo de monitoramento e retraining do modelo garantirá adaptação às mudanças de processo e maior ganho de eficiência.

Grupo Taking

OBRIGADO