Relatório de Entrega

SABO - Pipeline de Machine Learning

Manutenção Prescritiva para Extrusoras de Borracha Y125

Data: 14/04/2026

Sumário

• Resumo
• 1. Período dos Dados Analisados
• 2. Introdução
• 3. Descrição do Método Utilizado
• 4. Ferramentas Utilizadas
• 5. Modelos Estocásticos e Estatísticos Utilizados
• 6. Métricas
• 7. Dicionário Completo de Variáveis do Pipeline
• 7.1 Variáveis Originais (Dados Brutos)
• 7.2 Variáveis Geradas no Pré-processamento
• 7.3 Variáveis de Encoding (One-Hot)
• 7.4 Histórico de Troca de Peças por Equipamento
• 7.5 Features Utilizadas no Modelo Final
• 8. Dados Removidos da Análise
• 9. Desempenho de Modelos
• 10. Perguntas e Respostas
• 11. Previsão de Troca de Peças
• 12. Considerações
• 13. Próximos Passos
• 14. Recomendações
• 15. Considerações Finais
• 16. Análise Mensal por Equipamento
• Referência Bibliográfica

Resumo

Este relatório apresenta uma visão abrangente do projeto desenvolvido para prever a necessidade de manutenção em extrusoras de borracha modelo Y125, utilizando dados coletados em ambiente industrial. A iniciativa surgiu da observação de que, durante as manutenções preventivas, diversos componentes demonstraram uma vida útil significativamente maior que a inicialmente prevista pelo planejamento tradicional. Para viabilizar essa análise, foram coletados e organizados dados provenientes de múltiplos arquivos CSV, cada um associado a uma extrusora específica, contendo informações como quantidade produzida, refugada e retrabalhada, consumo de matéria-prima, datas de produção, códigos dos produtos e outros atributos operacionais. O dataset consolidado contém 41587 registros e 92 variáveis. Foi realizada a divisão dos dados em conjuntos de treinamento (33269 amostras, 80%) e teste (8318 amostras, 20%) para avaliação do poder preditivo dos modelos. Os resultados indicaram desempenho promissor. O modelo XGBOOST foi selecionado como melhor modelo, apresentando R^2 de 0.9538, MSE de 1085.97 e MAE de 18.36.

1. Período dos Dados Analisados

Período de Análise: 19/03/2023 a 31/03/2026 **Duração Total:** 1108 dias (36 meses aproximadamente) **Total de Registros:** 41587 registros de produção **Total de Peças Produzidas:** 19,724,127 peças

Base de Cálculo:

Os cálculos e análises apresentados neste relatório utilizam as seguintes bases: • **Análise Temporal:** Baseada em dias corridos desde o início da coleta de dados • **Análise de Produção:** Baseada na quantidade total de peças produzidas por período • **Análise de Desgaste:** Correlação entre volume de produção e indicadores de manutenção • **Previsões:** Calculadas em função do número de peças produzidas e/ou dias de operação Os gráficos apresentados podem utilizar diferentes unidades de medida conforme indicado em suas respectivas legendas: dias, meses ou quantidade de peças.

2. Introdução

A indústria moderna enfrenta o desafio constante de equilibrar segurança operacional e eficiência econômica. No contexto das extrusoras de borracha modelo Y125, observou-se que muitos componentes estavam sendo substituídos seguindo cronogramas fixos de manutenção preventiva, mesmo quando ainda apresentavam condições adequadas de funcionamento. Este cenário resulta em subutilização de peças, gerando custos desnecessários com componentes, mão de obra e tempo de máquina parada para intervenções prematuras. O objetivo deste projeto foi desenvolver e avaliar um modelo prescritivo capaz não apenas de prever com maior precisão o momento ideal para realizar a manutenção, mas também de prescrever intervenções específicas baseadas em dados, maximizando a vida útil dos componentes sem comprometer a confiabilidade do sistema produtivo.

3. Descrição do Método Utilizado

A metodologia seguiu um fluxo iterativo de cinco etapas principais, garantindo que o pipeline funcione de maneira eficiente e seja avaliado continuamente:

Coleta e Integração

Nesta etapa, os arquivos CSV provenientes de diferentes injetoras são reunidos. Cada arquivo traz dados como quantidade produzida, quantidade refugada, datas de produção, códigos de produto e informações sobre o consumo de massa. O objetivo é unificar esses dados em um DataFrame único para viabilizar análises consolidadas.

Pré-processamento e Limpeza

Uma vez que os dados estejam integrados, procede-se à limpeza. Isso envolve a remoção de possíveis duplicatas, conversão de campos de data para o formato apropriado (datetime), tratamento de valores ausentes, padronização de colunas e exclusão de registros inconsistentes. Além disso, nesta etapa ocorrem transformações como a codificação One-Hot para variáveis categóricas.

Análise Exploratória

Com os dados preparados, explora-se o conjunto para identificar padrões, outliers e tendências. São calculadas estatísticas descritivas (média, mediana, desvio padrão) e produzidos gráficos como histogramas, boxplots e gráficos de dispersão.

Modelagem (Treinamento)

Na fase de modelagem, definimos a variável-alvo (tempo até a próxima manutenção) e selecionamos algoritmos de aprendizado de máquina. Modelos como Regressão Linear, Decision Tree, Random Forest e XGBoost são treinados nos dados de treinamento (80% do total).

Validação e Avaliação

Após o treinamento, avalia-se o desempenho dos modelos em dados de teste (20%). Métricas como R^2, MSE e MAE são calculadas para verificar o quão próximo cada modelo chega do valor real.

4. Ferramentas Utilizadas

Python (3.x) para toda a etapa de análise e modelagem.

Pandas e NumPy para manipulação de dados e transformações.

Scikit-learn como principal biblioteca de Machine Learning.

XGBoost para algoritmos de gradient boosting.

Matplotlib/Seaborn para visualizações de gráficos.

Jupyter Notebooks para execução interativa de código.

5. Modelos Estocásticos e Estatísticos Utilizados

5.1 Regressão Linear

A Regressão Linear é uma técnica estatística clássica que busca entender a relação entre uma variável dependente (tempo até a manutenção) e variáveis independentes. O modelo assume a forma: $y \approx \beta 0 + \beta 1X1 + \beta 2X2 + ... + \beta nXn$.

5.2 Árvores de Decisão (Decision Tree)

As Árvores de Decisão organizam os dados em subdivisões baseadas em critérios estatísticos, como o erro quadrático médio. São úteis para dados com interações complexas ou não lineares.

5.3 Random Forest

O Random Forest combina diversas Árvores de Decisão para tornar as previsões mais precisas e estáveis. Geralmente apresenta menor variância que uma única árvore, sendo mais robusto a ruídos e outliers.

5.4 XGBoost (Extreme Gradient Boosting)

O XGBoost é um modelo avançado que constrói árvores de decisão sequencialmente, onde cada nova árvore aprende com os erros da anterior. Utiliza técnicas de regularização (L1 e L2) para evitar overfitting.

6. Métricas

6.1 Erro Quadrático Médio (EQM/MSE)

Mede a diferença entre os valores previstos pelo modelo e os valores reais, elevando essas diferenças ao quadrado. Quanto menor o EQM, mais precisas são as previsões do modelo.

6.2 R-quadrado (Coeficiente de Determinação)

O R-quadrado indica a proporção da variabilidade da variável dependente que é explicada pelo modelo. Seu valor varia entre 0 e 1, onde valores próximos de 1 indicam alta qualidade preditiva.

6.3 Erro Absoluto Médio (EAM/MAE)

Mede a média das diferenças absolutas entre os valores previstos e os reais. Ao contrário do EQM, não é tão sensível a erros extremos.

7. Dicionário Completo de Variáveis do Pipeline

Esta seção documenta todas as variáveis utilizadas no pipeline de Machine Learning, desde a coleta de dados brutos até as features utilizadas na modelagem. Cada variável é descrita com seu tipo, origem, uso e exemplos.

Total de variáveis no modelo final: 22 features

7.1 Variáveis Originais (Dados Brutos)

Variáveis coletadas diretamente dos arquivos CSV/XLSX dos equipamentos na Etapa 1.

Data de Produção

Nome Processado: Data_de_Producao
Tipo: datetime
Descrição: Data em que a produção foi realizada no equipamento.
Exemplo: 01/01/2024
Origem: Arquivo CSV do equipamento
Uso no Pipeline: Cálculo temporal, ordenação cronológica e cálculo da variável target.

Cód. Ordem

Nome Processado: Cod_Ordem
Tipo: int/string
Descrição: Código identificador único do lote ou ordem de produção. Representa um conjunto específico de peças fabricadas em uma mesma operação.
Exemplo: 1234567
Origem: Sistema de controle de produção (ERP)
Uso no Pipeline: Rastreabilidade, agrupamento de lotes e análise de padrões por ordem.

Cód. Recurso

Nome Processado: Cod_Recurso
Tipo: string
Descrição: Código do recurso produtivo (máquina/equipamento) utilizado na operação.
Exemplo: IJ-044
Origem: Sistema de controle de produção
Uso no Pipeline: Identificação do equipamento para análise individualizada.

Cód. Produto

Nome Processado: Cod_Produto
Tipo: string
Descrição: Código identificador único do produto fabricado. Cada código representa um tipo específico de peça de borracha.
Exemplo: SA05780
Origem: Cadastro de produtos
Uso no Pipeline: Análise de consumo por produto, categorização para One-Hot Encoding.

Qtd. Produzida

Nome Processado: Qtd_Produzida
Tipo: int
Descrição: Quantidade total de peças produzidas no registro. Representa o volume de produção efetiva do lote.
Unidade: peças
Exemplo: 1500
Origem: Apontamento de produção
Uso no Pipeline: Cálculo de acumulados, análise de desgaste, correlação com manutenção.

Qtd. Refugada

Nome Processado: Qtd_Refugada
Tipo: int
Descrição: Quantidade de peças refugadas (descartadas) por não atenderem aos padrões de qualidade. Indicador de qualidade do processo.
Unidade: peças
Exemplo: 25
Origem: Controle de qualidade
Uso no Pipeline: Indicador de qualidade, correlação com necessidade de manutenção.

Qtd. Retrabalhada

Nome Processado: Qtd_Retrabalhada
Tipo: int
Descrição: Quantidade de peças que necessitaram de retrabalho antes de serem aprovadas. Indica problemas intermediários no processo.
Unidade: peças
Exemplo: 10
Origem: Controle de qualidade
Uso no Pipeline: Indicador de eficiência, correlação com condição do equipamento.

Fator Un.

Nome Processado: Fator_Un
Tipo: float
Descrição: Fator de conversão de unidade. Usado para normalização de quantidades quando unidades diferem.
Exemplo: 1.0
Origem: Cadastro de produtos
Uso no Pipeline: Normalização de quantidades entre diferentes unidades de medida.

Cód. Un.

Nome Processado: Cod_Un
Tipo: string

Descrição: Código da unidade de medida utilizada para quantificar a produção.
Exemplo: PC (peças)
Origem: Cadastro de produtos
Uso no Pipeline: Identificação da unidade, categorização.

Descrição da massa (Composto)

Nome Processado: Descricao_da_massa_Composto
Tipo: string
Descrição: Tipo de composto ou material de borracha utilizado na fabricação. Diferentes compostos têm diferentes propriedades de desgaste.
Exemplo: N-142/67
Origem: Especificação técnica do produto
Uso no Pipeline: Análise de desgaste por tipo de material, One-Hot Encoding.

Consumo de massa no item em (Kg/100pçs)

Nome Processado: Consumo_de_massa_no_item_em_Kg_100pcs
Tipo: float
Descrição: Consumo de matéria-prima (borracha) por cada 100 peças produzidas. Indicador de eficiência de material.
Unidade: Kg/100 peças
Exemplo: 1.250
Origem: Cálculo baseado em consumo real
Uso no Pipeline: Análise de eficiência, detecção de anomalias de consumo.

Equipamento

Nome Processado: Equipamento
Tipo: string
Descrição: Identificador do equipamento/extrusora. Extraído do nome do arquivo de origem (IJ-XXX).
Exemplo: IJ-044
Origem: Nome do arquivo CSV
Uso no Pipeline: Agrupamento por equipamento, One-Hot Encoding, cálculo de troca de peças.

Fonte_Dados

Nome Processado: Fonte_Dados
Tipo: string
Descrição: Nome do arquivo de origem dos dados. Usado para rastreabilidade em arquivos com formato estendido.
Exemplo: IJ-138.2.xlsx
Origem: Sistema de arquivos

Uso no Pipeline: Rastreabilidade e auditoria de dados.

7.2 Variáveis Geradas no Pré-processamento (Etapa 2)

Variáveis criadas durante a Etapa 2 através de transformações e engenharia de features.

Manutencao

Nome Processado: Manutencao
Tipo: int
Descrição: VARIÁVEL TARGET - Número de dias restantes até a próxima manutenção programada do equipamento. Calculada como a diferença entre a data de manutenção conhecida e a data de produção.
Unidade: dias
Exemplo: 45
Origem: Calculada (data_manutencao - data_producao)
Uso no Pipeline: Variável alvo para os modelos de Machine Learning.
Fórmula: *Manutencao = Data_Manutenção_Equipamento - Data_de_Produção*

Qtd. Produzida_Acumulado

Nome Processado: Qtd_Produzida_Acumulado
Tipo: float
Descrição: Quantidade acumulada de peças produzidas por equipamento desde o início do período. Soma cumulativa ordenada por data.
Unidade: peças
Exemplo: 150000
Origem: Soma cumulativa por equipamento
Uso no Pipeline: Indicador de desgaste acumulado, correlação com necessidade de manutenção.
Fórmula: *cumsum(Qtd_Produzida) agrupado por Equipamento*

Qtd. Refugada_Acumulado

Nome Processado: Qtd_Refugada_Acumulado
Tipo: float
Descrição: Quantidade acumulada de peças refugadas por equipamento. Indica a evolução da taxa de refugo ao longo do tempo.
Unidade: peças
Exemplo: 2500
Origem: Soma cumulativa por equipamento
Uso no Pipeline: Tendência de qualidade, detecção de degradação.
Fórmula: *cumsum(Qtd_Refugada) agrupado por Equipamento*

Qtd. Retrabalhada_Acumulado

Nome Processado: Qtd_Retrabalhada_Acumulado
Tipo: float

Descrição: Quantidade acumulada de peças retrabalhadas por equipamento. Indica a evolução de problemas de processo.
Unidade: peças
Exemplo: 1200
Origem: Soma cumulativa por equipamento
Uso no Pipeline: Tendência de eficiência, correlação com condição do equipamento.
Fórmula: *cumsum(Qtd_Retrabalhada) agrupado por Equipamento*

Consumo de massa_Acumulado

Nome Processado: Consumo_de_massa_no_item_em_Kg_100pcs_Acumulado
Tipo: float
Descrição: Consumo acumulado de matéria-prima por equipamento. Permite análise de eficiência de material ao longo do tempo.
Unidade: Kg
Exemplo: 5000.50
Origem: Soma cumulativa por equipamento
Uso no Pipeline: Análise de consumo, detecção de anomalias de material.
Fórmula: *cumsum(Consumo_de_massa) agrupado por Equipamento*

7.3 Variáveis de Encoding (One-Hot)

Variáveis binárias criadas através de One-Hot Encoding para representar categorias. Cada categoria única gera uma coluna binária (0 ou 1).

Equipamento_*

Nome Processado: Equipamento_IJ-XXX
Tipo: int (0/1)
Descrição: Variáveis binárias para cada equipamento. Valor 1 indica que o registro pertence àquele equipamento específico.
Exemplo: Equipamento_IJ-044 = 1
Origem: One-Hot Encoding de 'Equipamento'
Uso no Pipeline: Permitir que modelos capturem comportamentos específicos de cada equipamento.
Categorias: *IJ-044, IJ-046, IJ-117, IJ-118, IJ-119, IJ-120, IJ-121, IJ-122, IJ-123, IJ-124, IJ-125, IJ-129, IJ-130, IJ-131, IJ-132, IJ-133, IJ-134, IJ-135, IJ-136, IJ-137, IJ-138, IJ-139, IJ-151, IJ-152, IJ-155, IJ-156, IJ-164*

Cod_Produto_*

Nome Processado: Cod_Produto_SAXXXXX
Tipo: int (0/1)
Descrição: Variáveis binárias para cada código de produto. Permite análise de impacto por tipo de produto.
Exemplo: Cod_Produto_SA05780 = 1
Origem: One-Hot Encoding de 'Cod_Produto'
Uso no Pipeline: Capturar diferenças de desgaste entre produtos.
Categorias: *Variável conforme produtos únicos no dataset*

Descricao_da_massa_*

Nome Processado: Descricao_da_massa_Composto_*
Tipo: int (0/1)
Descrição: Variáveis binárias para cada tipo de composto/material. Diferentes compostos causam diferentes níveis de desgaste.
Exemplo: Descricao_da_massa_Composto_N-142/67 = 1
Origem: One-Hot Encoding de 'Descrição da massa'
Uso no Pipeline: Análise de impacto de diferentes materiais no desgaste.
Categorias: *Variável conforme compostos únicos no dataset*

Cod_Un_*

Nome Processado: Cod_Un_*
Tipo: int (0/1)
Descrição: Variáveis binárias para cada unidade de medida.

Exemplo: Cod_Un_PC = 1
Origem: One-Hot Encoding de 'Cód. Un.'
Uso no Pipeline: Normalização entre diferentes unidades.
Categorias: *PC, UN, etc.*

7.4 Histórico de Troca de Peças por Equipamento

Datas das trocas efetivas de peças (substituição de componentes) e intervalo de operação para cada equipamento. Fonte: Dados Manut - 27 Equip - 2025.xlsx

Equipamento	Última Troca	Intervalo (dias)
IJ-044	2025-11-08	531
IJ-046	2025-01-05	343
IJ-117	2025-06-20	496
IJ-118	2025-03-02	385
IJ-119	2025-02-23	379
IJ-120	2025-04-05	406
IJ-121	2025-06-29	490
IJ-122	2025-05-17	448
IJ-123	2025-03-01	384
IJ-124	2025-01-04	332
IJ-125	2024-12-19	395
IJ-129	2025-05-03	433
IJ-130	2025-10-04	504
IJ-131	2025-02-15	356
IJ-132	2025-04-12	419
IJ-133	2025-07-05	490
IJ-134	2025-08-07	523
IJ-135	2025-07-07	492
IJ-136	2025-11-01	532
IJ-137	2025-09-06	538
IJ-138	2025-09-06	539
IJ-139	2025-02-08	342
IJ-151	2025-09-29	569
IJ-152	2025-08-17	526
IJ-156	2025-10-11	510
IJ-164	2025-04-27	406

Estatísticas de Intervalo entre Trocas:
Média: 453 dias | Mínimo: 332 dias | Máximo: 569 dias

7.5 Features Utilizadas no Modelo Final

O modelo final utiliza **22** features numéricas. Abaixo está a lista completa das features após todo o pré-processamento:

Features Numéricas Originais (18):

Cód_Ordem, Qtd_Produzida, Qtd_Refugada, Qtd_Retrabalhada, Fator_Un, Consumo_de_massa_no_item_em_Kg_100pçs, cilindro_max, cilindro_min, cilindro_variacao, desgaste_cilindro, fuso_max, fuso_min, fuso_variacao, desgaste_fuso, taxa_desgaste_cilindro, taxa_desgaste_fuso, indice_desgaste, desgaste_por_1000_pecas

Features Acumuladas (4):

Qtd_Produzida_Acumulado, Qtd_Refugada_Acumulado, Qtd_Retrabalhada_Acumulado, Consumo_de_massa_no_item_em_Kg_100pçs_Acumulado

8. Dados Removidos da Análise

Durante a fase de pré-processamento, foram eliminados ou desconsiderados alguns registros e variáveis por apresentarem inconsistências:

• Registros Duplicados: excluídos para evitar distorções na contagem.

• Linhas com Dados Inconsistentes: valores impossíveis ou datas inválidas.

• Valores Nulos Irrecuperáveis: quando variáveis essenciais estavam ausentes.

• Variáveis Redundantes: que não acrescentavam novas informações.

Nota sobre Integridade dos Dados (aplicável a partir desta versão):

Comparando esta versão do relatório com versões anteriores (ex.: R14, R15), podem haver divergências significativas no total de registros e na contagem de variáveis. Os números anteriores estavam afetados por três problemas de ingestão que foram identificados e corrigidos:

• **Dupla contagem de planilhas de produção:** quando o arquivo DadosProducao*.xlsx ficava acidentalmente em data/raw/, o pipeline carregava os mesmos registros duas vezes (uma via IJ-*.csv já splitado pelo s00, outra via leitura direta do xlsx), inflando o total. Corrigido movendo o xlsx para data/arquivo_unico_processado/ após o split, e o carregador direto só vê arquivos ainda não processados.

• **Sobrescrita silenciosa do baseline histórico:** um bloco except no s00 substituía os CSVs existentes por apenas os registros novos em caso de qualquer erro de leitura. A ingestão passou a preservar o histórico e logar o erro em vez de descartar dados.

• **Interpretação errada de datas em formato ISO:** aplicar dayfirst=True sobre datas no padrão YYYY-MM-DD (como "2026-01-12") fazia o pandas reinterpretá-las trocando mês e dia (resultando em "2026-12-01" — 1° de dezembro no futuro). A leitura agora tenta ISO 8601 primeiro e só recorre a dayfirst=True como fallback para valores no formato brasileiro dd/mm/yyyy.

Como consequência, este relatório apresenta um conjunto de dados menor em volume mas íntegro em conteúdo, com datas cronologicamente corretas e sem duplicações artificiais. As métricas de modelo permanecem comparáveis em qualidade (R^2 na mesma faixa), confirmando que o dataset depurado preserva o sinal preditivo.

9. Desempenho de Modelos

O modelo XGBOOST foi selecionado como o melhor modelo nos experimentos, destacando a capacidade de capturar padrões complexos de desgaste.

Quadro 1: Desempenho do Modelo Selecionado:

Modelo	EQM (MSE)	R-Quadrado	EAM (MAE)
XGBOOST	1085.97	0.9538	18.36

Gráficos de Análise

Os gráficos abaixo apresentam as análises exploratórias realizadas durante o desenvolvimento do modelo, incluindo matrizes de correlação, análises de distribuição e visualizações das principais features.

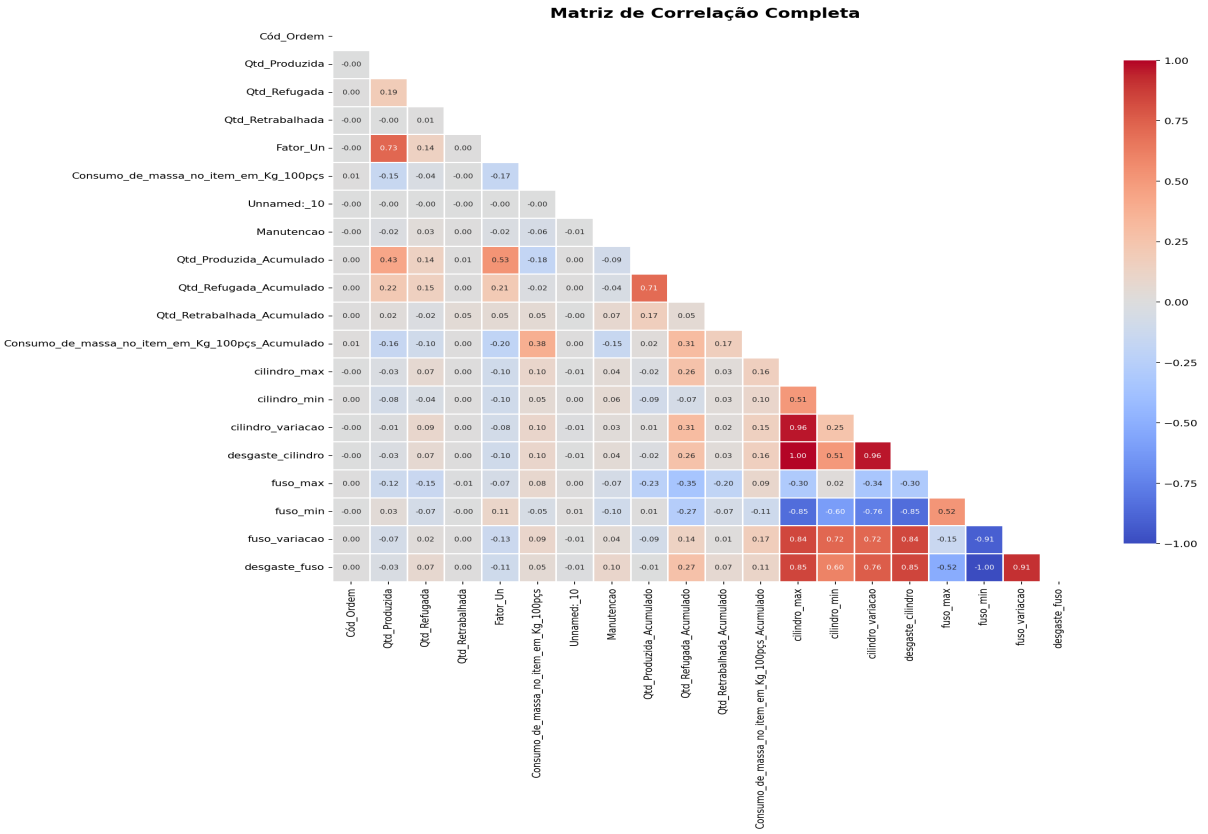

Figura 1: Matriz de Correlação Completa - Período: 19/03/2023 a 31/03/2026

Base: Quantidade de peças

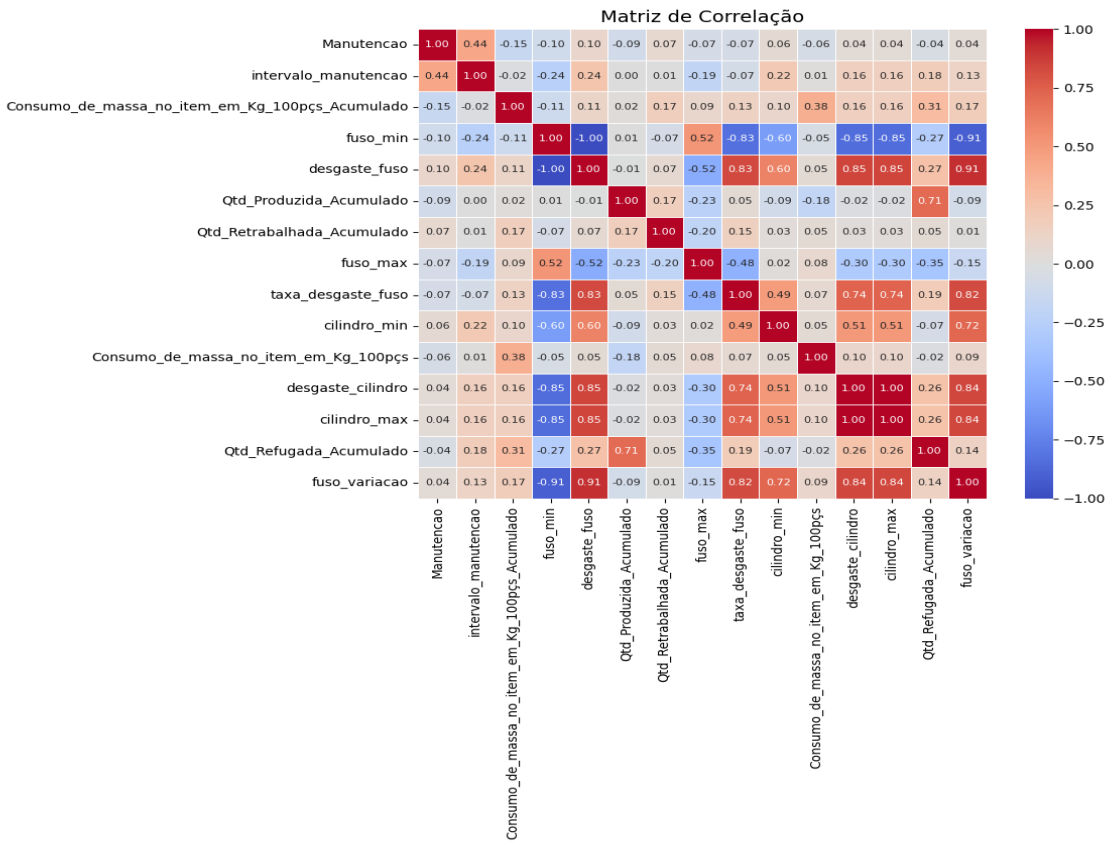

Figura 2: Heatmap de Correlação - Período: 19/03/2023 a 31/03/2026

Base: Quantidade de peças

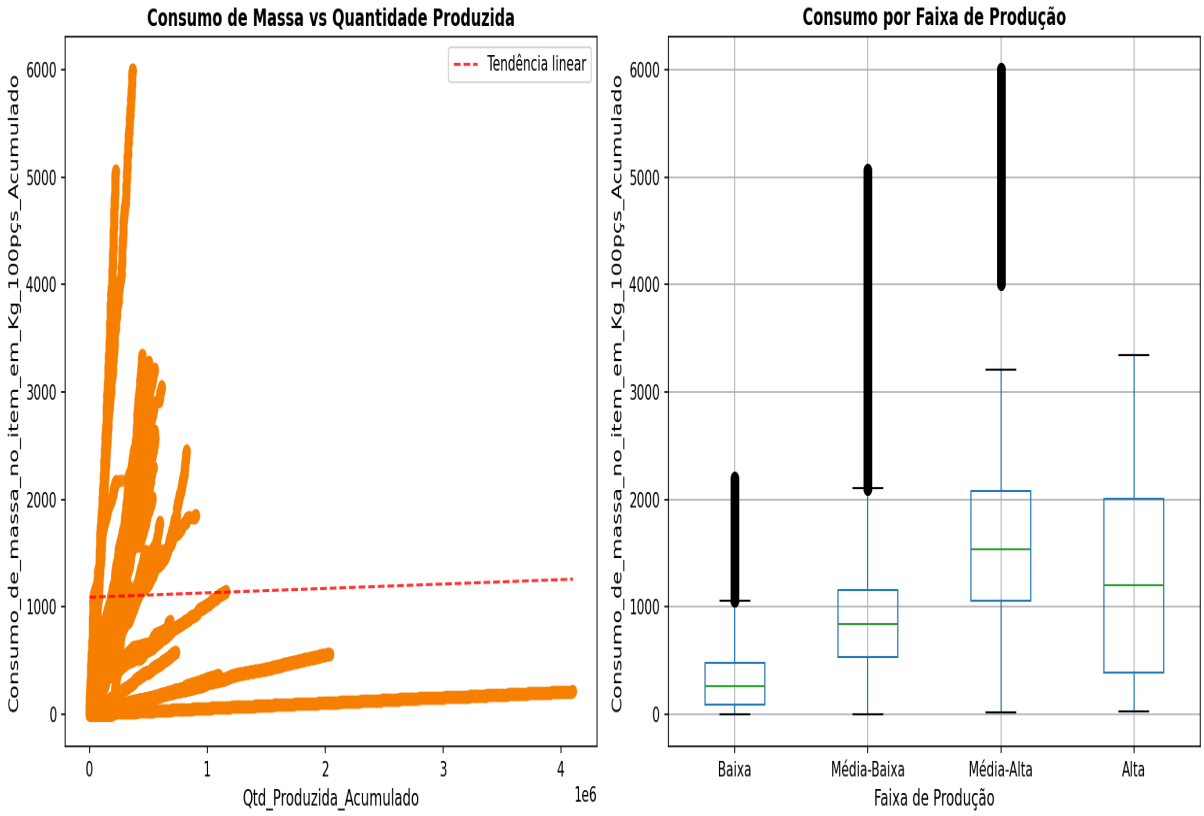

Figura 3: Análise de Consumo vs Produção - Período: 19/03/2023 a 31/03/2026

Base: Quantidade de peças

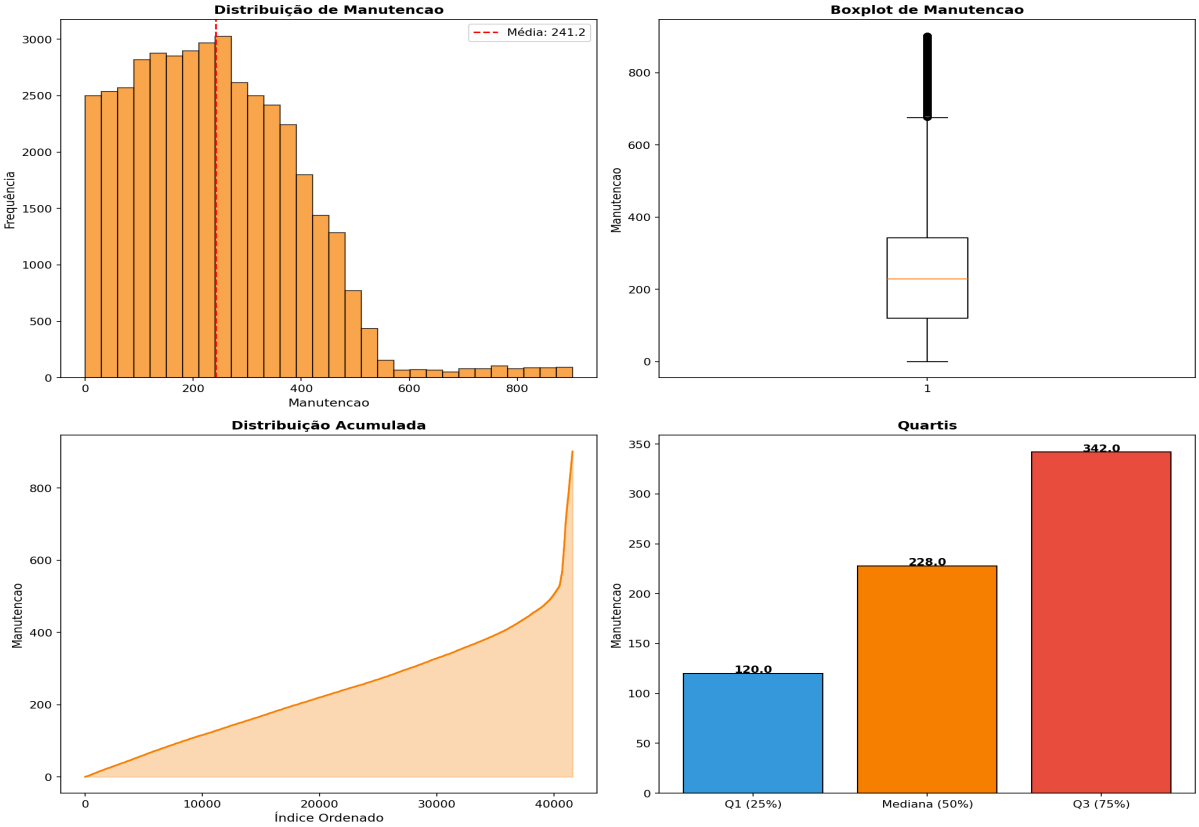

Figura 4: Análise Temporal - Período: 19/03/2023 a 31/03/2026 (1108 dias)

Base: Dias

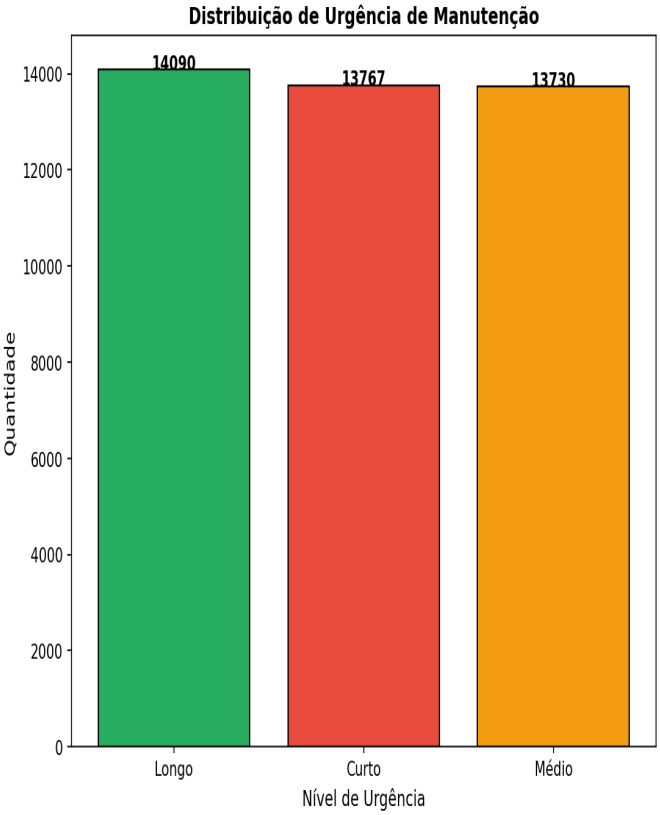

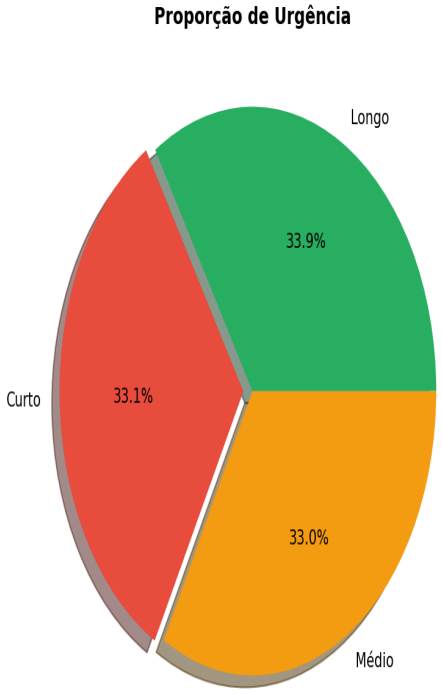

Figura 5: Distribuição de Urgência de Manutenção - Período: 19/03/2023 a 31/03/2026

Base: Classificação por nível de urgência

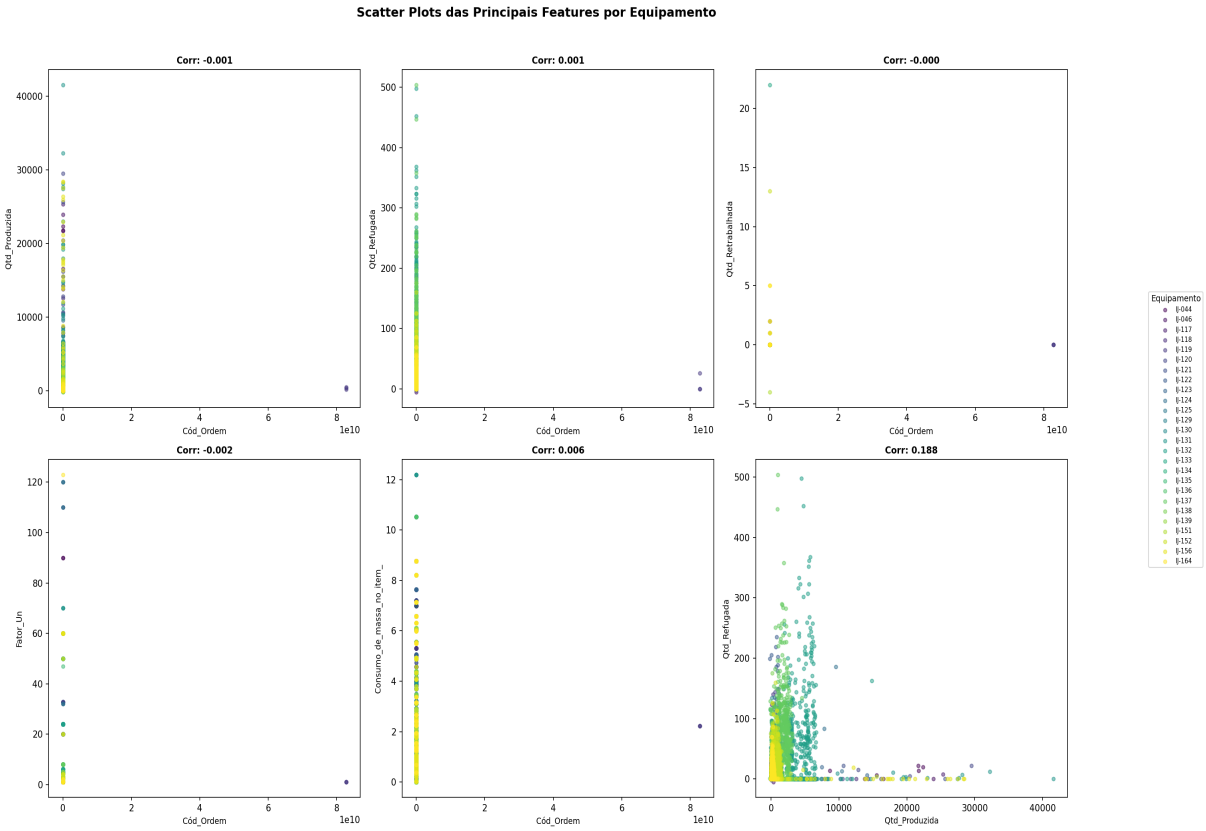

Figura 6: Scatter Plots das Features por Equipamento - Período: 19/03/2023 a 31/03/2026

Base: Valores das variáveis coloridos por equipamento

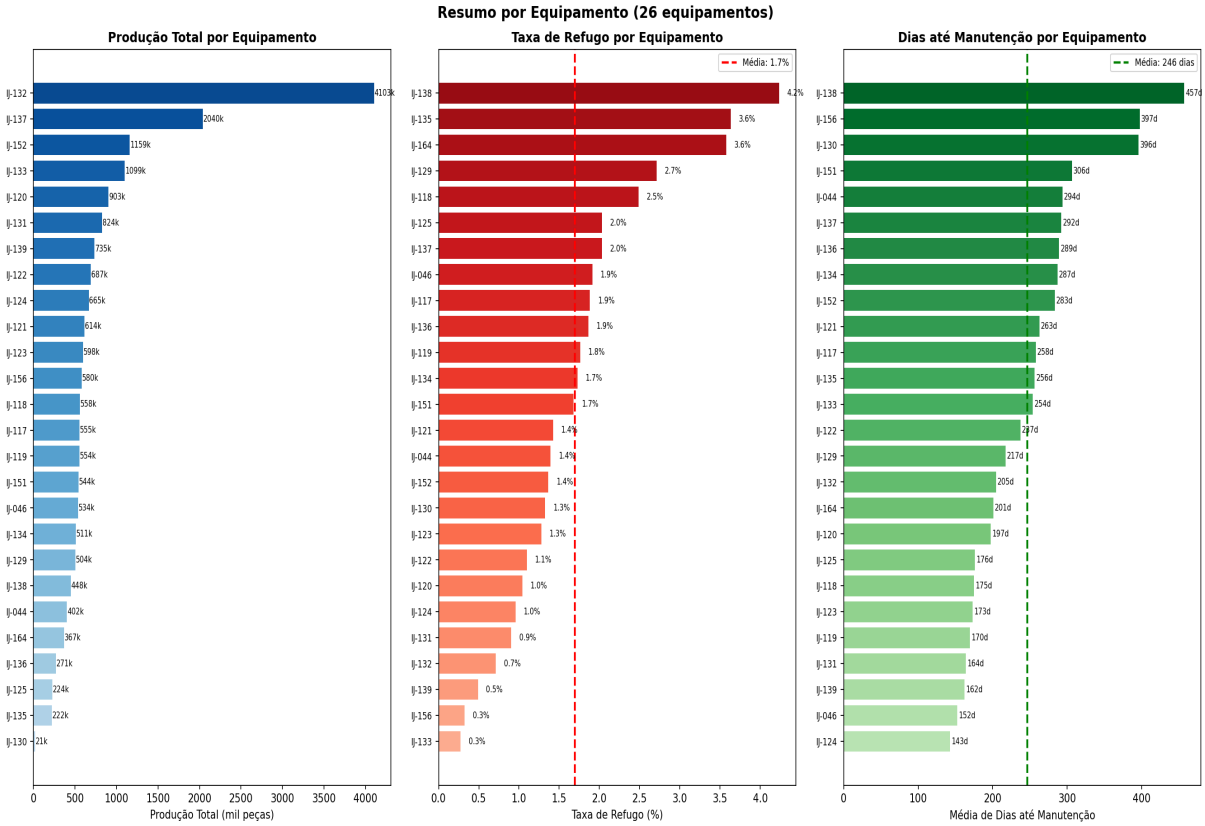

Figura 7: Resumo por Equipamento - Período: 19/03/2023 a 31/03/2026

Base: Produção, Refugo e Dias até Manutenção

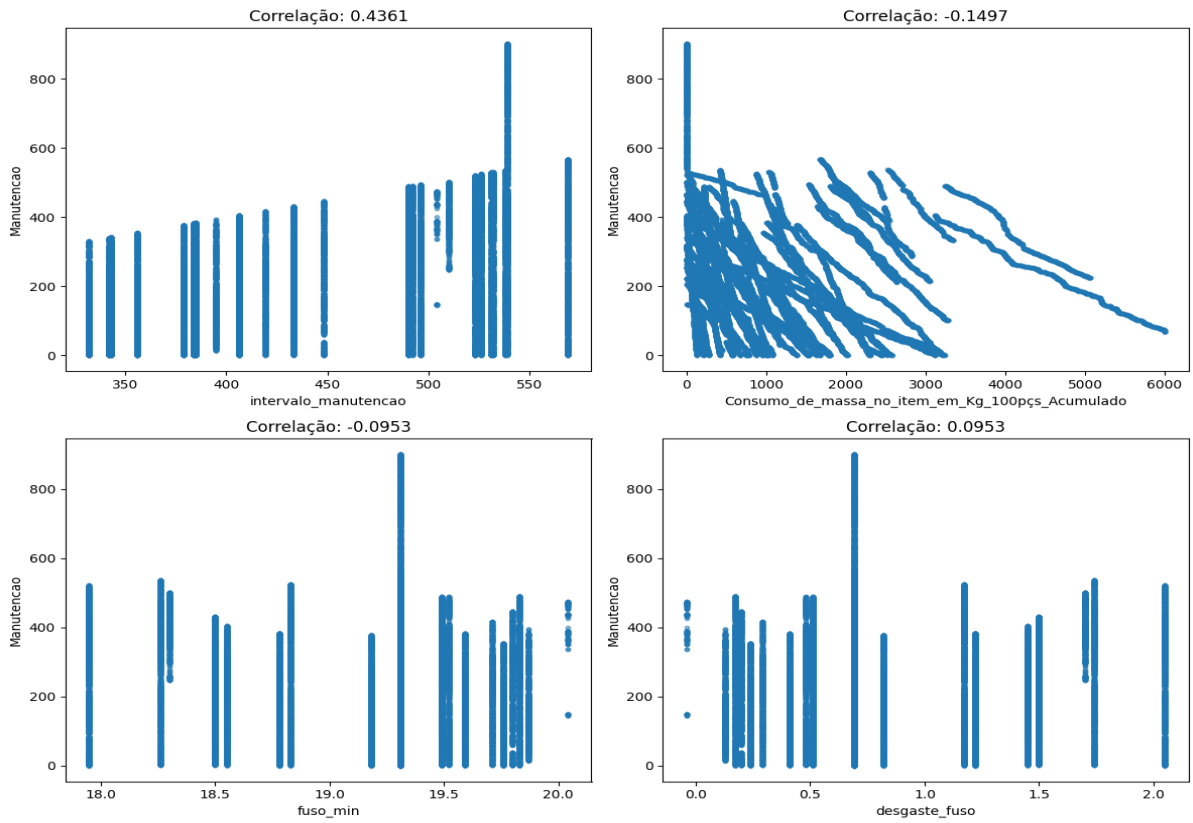

Figura 8: Dispersão do Target - Período: 19/03/2023 a 31/03/2026

Base: Valores preditos vs reais

10. Perguntas e Respostas

10.1 Como interpretar os gráficos?

Os gráficos apresentados utilizam dados do período de **19/03/2023** a **31/03/2026**. A base de cálculo varia conforme o tipo de análise: gráficos temporais utilizam dias ou meses como unidade, enquanto gráficos de produção utilizam quantidade de peças. A legenda de cada gráfico indica a unidade utilizada.

10.2 Qual a confiabilidade das previsões?

O modelo XGBOOST apresentou R^2 de 0.9538, o que significa que aproximadamente 95.4% da variação nos dados é explicada pelo modelo. O erro médio absoluto (MAE) de 18.36 indica a margem de erro típica das previsões.

10.3 Os dados são representativos?

A análise foi baseada em 41587 registros coletados ao longo de 1108 dias (36 meses). Para maior robustez estatística, recomenda-se mínimo de 30 observações por cenário, sendo ideal entre 50 e 100.

10.4 Como o modelo foi validado?

Os dados foram divididos em conjunto de treinamento (33269 amostras, 80%) e teste (8318 amostras, 20%). O modelo foi treinado apenas com dados de treinamento e avaliado em dados nunca vistos (teste), garantindo avaliação imparcial.

11. Previsão de Troca de Peças

11.1 Previsão Histórica (Baseada em Intervalos)

Esta tabela apresenta a previsão baseada no **intervalo histórico** entre trocas de peças. O cálculo é simples: Próxima Troca = Última Troca + Intervalo Médio Histórico. É útil como referência, mas não considera o estado atual do equipamento.

Equipamento	Última Troca	Intervalo Hist.	Próx. Troca	Dias Restantes
IJ-044	08/11/2025	531 dias	23/04/2027	373 dias
IJ-046	05/01/2025	343 dias	14/12/2025	-122 (ATRASADO)
IJ-117	20/06/2025	496 dias	29/10/2026	197 dias
IJ-118	02/03/2025	385 dias	22/03/2026	-24 (ATRASADO)
IJ-119	23/02/2025	379 dias	09/03/2026	-37 (ATRASADO)
IJ-120	05/04/2025	406 dias	16/05/2026	31 dias
IJ-121	29/06/2025	490 dias	01/11/2026	200 dias
IJ-122	17/05/2025	448 dias	08/08/2026	115 dias
IJ-123	01/03/2025	384 dias	20/03/2026	-26 (ATRASADO)
IJ-124	04/01/2025	332 dias	02/12/2025	-134 (ATRASADO)
IJ-125	19/12/2024	395 dias	18/01/2026	-87 (ATRASADO)
IJ-129	03/05/2025	433 dias	10/07/2026	86 dias
IJ-130	04/10/2025	504 dias	20/02/2027	311 dias
IJ-131	15/02/2025	356 dias	06/02/2026	-68 (ATRASADO)
IJ-132	12/04/2025	419 dias	05/06/2026	51 dias
IJ-133	05/07/2025	490 dias	07/11/2026	206 dias
IJ-134	07/08/2025	523 dias	12/01/2027	272 dias
IJ-135	07/07/2025	492 dias	11/11/2026	210 dias
IJ-136	01/11/2025	532 dias	17/04/2027	367 dias
IJ-137	06/09/2025	538 dias	26/02/2027	317 dias
IJ-138	06/09/2025	539 dias	27/02/2027	318 dias
IJ-139	08/02/2025	342 dias	16/01/2026	-89 (ATRASADO)
IJ-151	29/09/2025	569 dias	21/04/2027	371 dias
IJ-152	17/08/2025	526 dias	25/01/2027	285 dias
IJ-156	11/10/2025	510 dias	05/03/2027	324 dias
IJ-164	27/04/2025	406 dias	07/06/2026	53 dias

11.2 Previsão Prescritiva (Modelo de Machine Learning)

Esta tabela apresenta a previsão do **modelo XGBOOST** ($R^2 = 0.9538$), que considera o **estado atual** de cada equipamento: produção acumulada, índice de desgaste, taxa de refugo, medições de cilindro/fuso, entre outros fatores. Esta é a **previsão recomendada** para tomada de decisão.

Equipamento	Última Troca	Previsão ML	Próx. Troca ML	Status
IJ-044	08/11/2025	418 dias	06/06/2027	OK
IJ-046	05/01/2025	33 dias	17/05/2026	ATENÇÃO
IJ-117	20/06/2025	223 dias	23/11/2026	OK
IJ-118	02/03/2025	33 dias	17/05/2026	ATENÇÃO
IJ-119	23/02/2025	17 dias	01/05/2026	URGENTE
IJ-120	05/04/2025	60 dias	13/06/2026	ATENÇÃO
IJ-121	29/06/2025	234 dias	04/12/2026	OK
IJ-122	17/05/2025	140 dias	01/09/2026	OK
IJ-123	01/03/2025	26 dias	10/05/2026	URGENTE
IJ-124	04/01/2025	19 dias	03/05/2026	URGENTE
IJ-125	19/12/2024	91 dias	14/07/2026	OK
IJ-129	03/05/2025	102 dias	25/07/2026	OK
IJ-130	04/10/2025	372 dias	21/04/2027	OK
IJ-131	15/02/2025	26 dias	10/05/2026	URGENTE
IJ-132	12/04/2025	104 dias	27/07/2026	OK
IJ-133	05/07/2025	238 dias	08/12/2026	OK
IJ-134	07/08/2025	289 dias	28/01/2027	OK
IJ-135	07/07/2025	242 dias	12/12/2026	OK
IJ-136	01/11/2025	352 dias	01/04/2027	OK
IJ-137	06/09/2025	353 dias	02/04/2027	OK
IJ-138	06/09/2025	341 dias	21/03/2027	OK
IJ-139	08/02/2025	23 dias	07/05/2026	URGENTE
IJ-151	29/09/2025	387 dias	06/05/2027	OK
IJ-152	17/08/2025	356 dias	05/04/2027	OK
IJ-156	11/10/2025	342 dias	22/03/2027	OK
IJ-164	27/04/2025	91 dias	14/07/2026	OK

Legenda de Status:
- **ATRASADO**: Troca já deveria ter sido realizada
- **URGENTE**: Menos de 30 dias para a próxima troca
- **ATENÇÃO**: Entre 30 e 90 dias para a próxima troca
- **OK**: Mais de 90 dias até a próxima troca

11.3 Comparação: Histórico vs. ML

A tabela abaixo compara as duas abordagens, destacando a diferença entre a previsão histórica (baseada apenas no intervalo entre trocas) e a previsão do modelo ML (que considera múltiplos fatores):

Equipamento	Previsão Histórica	Previsão ML	Diferença	Recomendação
IJ-044	373 dias	418 dias	+45 dias	Pode adiar
IJ-046	-122 dias	33 dias	+155 dias	Pode adiar
IJ-117	197 dias	223 dias	+26 dias	Conforme
IJ-118	-24 dias	33 dias	+57 dias	Pode adiar
IJ-119	-37 dias	17 dias	+54 dias	Pode adiar
IJ-120	31 dias	60 dias	+29 dias	Conforme
IJ-121	200 dias	234 dias	+34 dias	Pode adiar
IJ-122	115 dias	140 dias	+25 dias	Conforme
IJ-123	-26 dias	26 dias	+52 dias	Pode adiar
IJ-124	-134 dias	19 dias	+153 dias	Pode adiar
IJ-125	-87 dias	91 dias	+178 dias	Pode adiar
IJ-129	86 dias	102 dias	+16 dias	Conforme
IJ-130	311 dias	372 dias	+61 dias	Pode adiar
IJ-131	-68 dias	26 dias	+94 dias	Pode adiar
IJ-132	51 dias	104 dias	+53 dias	Pode adiar
IJ-133	206 dias	238 dias	+32 dias	Pode adiar
IJ-134	272 dias	289 dias	+17 dias	Conforme
IJ-135	210 dias	242 dias	+32 dias	Pode adiar
IJ-136	367 dias	352 dias	-15 dias	Conforme
IJ-137	317 dias	353 dias	+36 dias	Pode adiar
IJ-138	318 dias	341 dias	+23 dias	Conforme
IJ-139	-89 dias	23 dias	+112 dias	Pode adiar
IJ-151	371 dias	387 dias	+16 dias	Conforme
IJ-152	285 dias	356 dias	+71 dias	Pode adiar
IJ-156	324 dias	342 dias	+18 dias	Conforme
IJ-164	53 dias	91 dias	+38 dias	Pode adiar

Interpretação:
• **Antecipar**: O modelo ML indica que o equipamento pode precisar de manutenção antes do previsto pelo histórico
• **Pode adiar**: O modelo ML indica que o equipamento está em bom estado e pode operar mais tempo
• **Conforme**: Previsão ML próxima da histórica (diferença ≤ 30 dias)

11.4 Fatores Considerados pelo Modelo ML

O modelo de Machine Learning considera 22 variáveis para determinar a necessidade de troca de peças. As principais são:

• **Produção Acumulada**: Volume total de peças produzidas desde a última troca

- **Índice de Desgaste**: Score combinado (0-100) baseado nas medições de cilindro e fuso
- **Medições de Cilindro**: Variação, máximo e mínimo das medições do cilindro
- **Medições de Fuso**: Variação, máximo e mínimo das medições do fuso
- **Taxa de Refugo/Retrabalho**: Indicadores de qualidade acumulados
- **Consumo de Massa**: Consumo de matéria-prima em relação à produção
- **Taxa de Desgaste**: Desgaste por unidade de tempo ou produção

12. Considerações

O desenvolvimento de um projeto de manutenção prescritiva para injetoras de borracha demonstrou o potencial de algoritmos de Machine Learning não apenas para prever o momento ideal de manutenção, mas para prescrever intervenções específicas baseadas nos padrões identificados.

O ensaio de diferentes algoritmos (Regressão Linear, Decision Tree, Random Forest e XGBoost) evidenciou que modelos de ensemble tendem a produzir resultados superiores quando há volume de dados adequado.

13. Próximos Passos

Shadow Teste: Executar o modelo em operação paralela à linha produtiva, sem intervenções reais.

Sistema de Recomendações: Criar regras que traduzam resultados em recomendações de intervenção.

Implantação em Produção: Adoção gradativa começando por linha-piloto.

Validação Contínua: Incorporar dados recentes de forma recorrente.

Incorporar Variáveis de Campo: Incluir dados de temperatura, vibração e pressão.

14. Recomendações

• Desenvolvimento de Biblioteca de Recomendações Prescritivas

• Plano Estruturado de Coleta e Qualidade de Dados

• Cultura de manutenção baseada em dados

• Integração com Sistemas de Produção

• Pipelines de Teste e Retreinamento

• Explorar Novos Modelos e Técnicas de Interpretação

• Foco nos Benefícios Financeiros e Estratégicos

15. Considerações Finais

Os resultados preliminares revelaram boas perspectivas para métodos como XGBOOST. A incorporação de novas amostras tende a aumentar a precisão das previsões, viabilizando uma manutenção realmente prescritiva, que não apenas prevê quando intervir, mas também determina as ações específicas necessárias.

Como parâmetro de amostragem mínima, recomenda-se reunir ao menos 30 observações para cada cenário relevante, sendo a faixa ideal entre 50 e 100 observações para garantir maior robustez estatística.

16. Análise Mensal por Equipamento

Os gráficos abaixo apresentam a análise mensal de cada equipamento, incluindo quantidade de peças produzidas, peças refugadas e momentos de manutenção. Período exibido: últimos 6 meses dos dados analisados (19/03/2023 a 31/03/2026).

Figura: Análise Mensal - Página 1

Figura: Análise Mensal - Página 2

Figura: Análise Mensal - Página 3

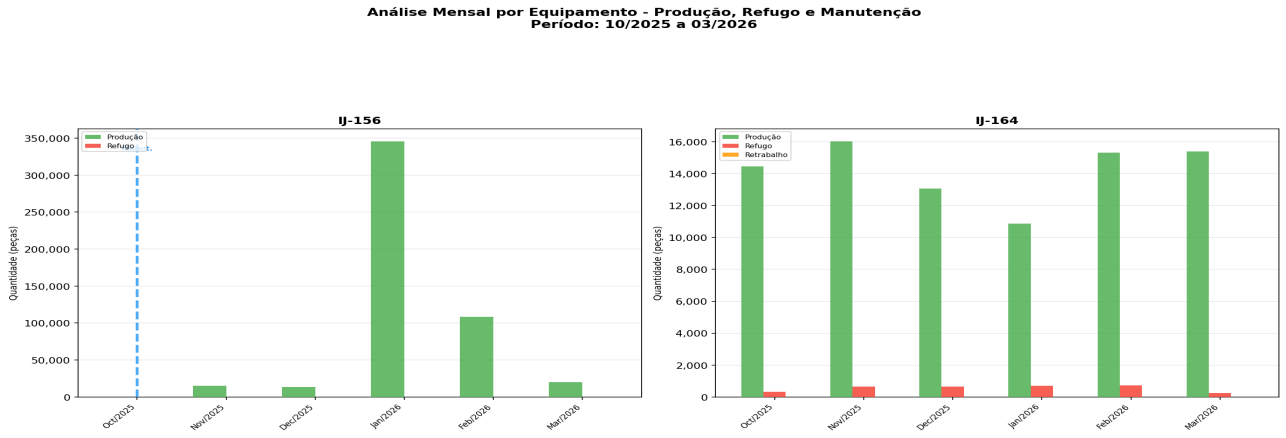

Figura: Análise Mensal - Página 4

Referência Bibliográfica

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and Regression Trees. Wadsworth.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. ACM SIGKDD.

Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.